

Optimización de carteras mediante aprendizaje supervisado: Un enfoque basado en XGBoost integrado con indicadores macroeconómicos y técnicos (2015-2025)

UOC

Eloi Arjona

Máster Data Science

Área 1

Tutor/a de TF

Rafael Luque Ocaña

Profesor/a responsable de la asignatura

Susana Acedo

05/2026

Universitat Oberta
de Catalunya



Esta obra está sujeta a una licencia de Reconocimiento-
NoComercial-SinObraDerivada [3.0 España de Creative Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

B) GNU Free Documentation License (GNU FDL)

Copyright © 2026 Eloi Arjona Guimera.

Permission is granted to copy, distribute and/or modify this document under the terms of the GNU Free Documentation License, Version 1.3 or any later version published by the Free Software Foundation; with no Invariant Sections, no Front-Cover Texts, and no Back-Cover Texts.

A copy of the license is included in the section entitled "GNU Free Documentation License".

C) Copyright

© (el autor/a)

Reservados todos los derechos. Está prohibido la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la impresión, la reprografía, el microfilme, el tratamiento informático o cualquier otro sistema, así como la distribución de ejemplares mediante alquiler y préstamo, sin la autorización escrita del autor o de los límites que autorice la Ley de Propiedad Intelectual.

Ficha del Trabajo Final

Título del trabajo:	Optimización de carteras mediante aprendizaje supervisado: Un enfoque basado en XGBoost integrado con indicadores macroeconómicos y técnicos (2015-2025)
Nombre del autor/a:	Eloi Arjona Guimera
Nombre del Tutor/a de TF:	Rafael Luque Ocaña
Nombre del/de la PRA:	Susana Acedo
Fecha de entrega:	06/2026
Titulación o programa:	Máster Data Science
Área del Trabajo Final:	Área 1
Idioma del trabajo:	Castellano
Palabras clave	Aprendizaje automático financiero, Selección de activos, Análisis macroeconómico cuantitativo.
Resumen del Trabajo	
El presente Trabajo de Fin de Máster investiga si es posible superar la gestión pasiva tradicional mediante la integración sistemática de variables macroeconómicas y técnicas en modelos de aprendizaje automático. En un escenario financiero global caracterizado por cambios abruptos de régimen y volatilidad, el inversor actual enfrenta el reto de rentabilizar su capital preservando su poder adquisitivo real. Este proyecto propone una solución algorítmica basada en el modelo <i>Extreme Gradient Boosting</i> (XGBoost), implementando una arquitectura de datos unificada a través de la API de Yahoo Finance (yfinance). El pipeline procesa osciladores técnicos de precio e integra un modelado endógeno de regímenes de inflación anual combinado con proxies clave de renta fija (rendimiento de los bonos soberanos) y del sentimiento de mercado (<i>Volatility Index</i>, VIX). Esta aproximación permite capturar interacciones no lineales complejas entre el entorno macroeconómico y una muestra estratificada sectorialmente de 50 activos del mercado estadounidense bajo la clasificación GICS. El objetivo central es evaluar la eficacia y adaptabilidad de esta estrategia de selección de activos (<i>stock picking</i>) entrenada en el bloque 2015-2022 y examinada de forma ciega (<i>Out-of-sample</i>) durante el periodo de restricción	

monetaria 2023-2025. La investigación culmina en un *backtesting* riguroso de rebalanceo mensual que evalúa dos configuraciones de cartera equiponderadas: una de alta convicción (Top 5) y otra diversificada (Top 10). Para determinar el éxito del sistema, el rendimiento y las métricas de riesgo (Ratio de Sharpe, Sortino y *Max Drawdown*) se comparan sistemáticamente contra el índice S&P 500 como *benchmark*. Este enfoque multidimensional permite concluir que la inteligencia artificial es capaz de generar un "Alfa" real, aportando consistencia, transparencia mediante interpretabilidad científica y una sólida protección patrimonial ante los cambios estructurales del ciclo económico moderno.

Abstract

This Master's Thesis investigates whether it is possible to outperform traditional passive management through the systematic integration of macroeconomic and technical variables into machine learning models. In a global financial landscape characterized by abrupt regime shifts and high volatility, today's investor faces the challenge of generating returns while preserving real purchasing power. This project proposes an algorithmic solution based on the Extreme Gradient Boosting (XGBoost) model, implementing a unified data architecture through the Yahoo Finance API (yfinance). The pipeline processes technical price oscillators and integrates an endogenous modeling of annual inflation regimes, combined with key fixed-income proxies (sovereign bond yields) and market sentiment indicators (Volatility Index, VIX). This approach captures complex non-linear interactions between the macroeconomic environment and a sector-stratified sample of 50 US equities under the GICS classification.

The central objective is to evaluate the effectiveness and adaptability of this stock-picking strategy, trained on the 2015–2022 historical block and tested blindly within an out-of-sample framework during the 2023–2025 monetary tightening period. The research culminates in a rigorous monthly rebalancing backtest evaluating two equally-weighted portfolio configurations: a high-conviction strategy (Top 5) and a diversified approach (Top 10). To determine the system's success, performance and risk metrics (Sharpe Ratio, Sortino Ratio, and Maximum Drawdown) are systematically benchmarked against the S&P 500 index. This multidimensional approach demonstrates that artificial

intelligence is capable of generating true "Alpha," delivering consistency, transparency through scientific interpretability, and robust capital protection against structural changes in the modern economic cycle.

Índice

1.	Introducción	1
1.1.	Contexto y justificación del Trabajo	1
1.2.	Objetivos del Trabajo	2
1.3.	Impacto en sostenibilidad, ético-social y de diversidad	3
1.4.	Enfoque y método seguido	4
	Técnicas de obtención de datos y herramientas	5
	Valoración de la estrategia	5
1.5.	Planificación del trabajo	6
	Recursos de Hardware	6
	Recursos de Software y Programación	7
	Fuentes de Datos (Data Resources)	7
	Recursos Académicos y de Gestión	8
	Gestión y control de la planificación	8
	Criterios de control establecidos	8
1.6.	Metodología de Gestión del Proyecto	10
1.7.	Identificación y gestión de riesgos	11
1.8.	Breve resumen de productos obtenidos	12
1.9.	Breve descripción de otros capítulos de la memoria	13
2.	Materiales y métodos	14
2.1.	Fundamentación Técnica y Estado del Arte	15
	Evolución del Machine Learning en la Gestión de Activos	15
	Relevancia de las variables macroeconómicas en la predicción de mercados	16
	Idoneidad del algoritmo XGBoost en la selección de activos	17
2.2.	Metodología y Toma de Decisiones	19
	Selección e Ingeniería de Variables (Feature Engineering)	19
	Alternativas consideradas y criterios de diseño	21
	Validación temporal mediante Split Cronológico (Out-of-sample)	23
	Criterios de Selección de Activos (Asset Selection)	24
2.3.	Descripción del Producto y Arquitectura	25
	Configuración técnica del modelo en Python: Librerías y entorno	25
	Automatización e Ingesta de Datos (Data Ingestion)	26

Generación de señales y métricas de riesgo	27
2.4. Valoración económica del trabajo final de máster	28
Análisis de recursos humanos y tecnológicos	28
Sostenibilidad y modelo profesional	29
3. Resultados	30
3.1. Análisis del Conjunto de Datos y Muestra de Activos	31
Selección del Universo de Inversión y Estratificación	31
Protocolo de Supervivencia y Calidad del Datos	32
Dimensionamiento del Dataset Final	33
3.2. Consolidación de la Tabla Maestra y Armonización de Fuentes	33
Integración de Flujos de Datos (Multifuentes)	34
Transformación de Frecuencia y Reducción de Ruido	34
Estructura de la Tabla Maestra (Feature Set)	35
Resultado del Conjunto de Datos y Balance de Clases	36
3.3. Arquitectura y Lógica del Algoritmo XGBoost	37
Configuración de Hiperparámetros y Estrategia de Aprendizaje	37
Análisis Detallado de la Precisión (Accuracy) y Errores	39
Interpretación Socioeconómica de las Variables (Feature Importance)	42
Salida del Software y Preparación del Backtesting	44
3.4. Motor de Simulación Monetaria y Gestión de Cartera	46
Lógica Algorítmica del Simulador	46
Composición de Carteras y Selección de Activos	47
Correlación con el Escenario Macroeconómico y Volatilidad	49
Análisis de Resultados: IA vs. Estrategia Pasiva (S&P 500)	51
Dashboard de Performance Consolidado: Análisis de Atribución y Eficiencia del Modelo Predictivo XGBoost	54
4. Conclusiones y trabajos futuros	59
4.1. Conclusiones del trabajo	59
4.2. Reflexión crítica sobre los objetivos	60
4.3. Análisis de la planificación y metodología	61
4.4. Evaluación de Impactos en sostenibilidad ético-social	62
4.5. Líneas de trabajo futuro	63
5. Glosario	65

6.	Bibliografia	68
7.	Anexos	70
7.1.	Diccionario de Activos y Clasificación Sectorial	70
7.2.	Código Fuente del Proyecto (Python)	71
	Configuración Inicial e Instalación de Librerías	72
	Selección de Universo y Extracción de Activos	73
	Ingeniería de Variables y Generación del Dataset Maestro	77
	Entrenamiento y Evaluación del Modelo Predictivo (XGBoost)	79
	Simulador de Carteras y Backtesting Dinámico	81
	Dashboard de Inteligencia de Mercado y Gestión de Carteras	85
7.3.	Protocolo de Replicabilidad (Pipeline de Ejecución)	87
	Requisitos y Configuración Inicial	87
	Secuencia del Pipeline Modular	87
	Verificación de Integridad	88
7.4.	Repositorio Digital y Entregables (GitHub)	88

Lista de Figuras

Figura 1	6
Figura 2	9
Figura 3	11
Figura 4	11
Figura 5	18
Figura 6	21
Figura 7	22
Figura 8	24
Figura 9	28
Figura 10	31
Figura 11	32
Figura 12	33
Figura 13	37
Figura 14	39
Figura 15	41
Figura 16	43
Figura 17	44
Figura 18	47
Figura 19	49
Figura 20	51
Figura 21	52
Figura 22	54
Figura 23	55
Figura 24	56
Figura 25	56
Figura 26	57
Figura 27	58
Figura 28	58
Figura 29	71
Figura 30	72
Figura 31	75
Figura 32	76
Figura 33	78
Figura 34	80
Figura 35	85
Figura 36	86

1. Introducció

Este apartado, expone la propuesta formal del Trabajo de Fin de Máster centrado en la optimización de carteras de inversión mediante Extreme Gradient Boosting (XGBoost) [14]. El proyecto, evalúa la capacidad predictiva de los modelos de Machine Learning, al integrar variables macroeconómicas, como la inflación y los tipos de interés, en un entorno de mercado volátil. A través de una metodología basada en el backtesting y la validación temporal, se busca desarrollar un sistema que apoye la selección estratégica de activos.

1.1. Contexto y justificación del Trabajo

La relevancia de este trabajo se sustenta en la evolución del sector financiero, donde la gestión de activos tradicional a menudo se enfrenta a dificultades para adaptarse a la rapidez de los mercados actuales. La justificación de este proyecto se divide en tres dimensiones:

- **Dimensión económica y social:** Tras un largo periodo de estabilidad, el escenario global actual de inflación y cambios en los tipos de interés afecta directamente al poder adquisitivo. Este trabajo se justifica por la necesidad de explorar herramientas que ayuden a proteger el ahorro, comparando el rendimiento de la cartera no solo con el mercado, sino con activos refugio como el Bono a 10 años.
- **Relevancia técnica:** Aunque el uso de algoritmos en finanzas es habitual, integrar variables macroeconómicas (como los bonos a 10 años o la **tasa de inflación**) dentro de modelos como **XGBoost** [14], permite explorar relaciones no lineales que los análisis simples pueden pasar por alto. El interés técnico reside en aplicar una metodología de *Data Science* para intentar capturar ineficiencias de mercado de forma sistemática.
- **Oportunidad tecnológica:** El acceso actual a datos históricos y capacidad de cómputo, permite implementar estrategias avanzadas de forma accesible. Este trabajo justifica su viabilidad, demostrando que es posible estructurar un sistema de decisión algorítmica profesional para gestionar diferentes volúmenes de capital de manera eficiente.

La motivación principal de este proyecto nace de mi práctica como inversor en el mercado de renta variable estadounidense. Al gestionar una cartera de acciones del S&P 500, he identificado la necesidad de profesionalizar el proceso de selección de activos:

- **Sistematización de decisiones:** Mi interés radica en evolucionar desde un análisis más discrecional hacia un enfoque cuantitativo. Me motiva el desafío de utilizar el *Machine Learning* para reducir sesgos emocionales e identificar activos con mayor potencial de crecimiento de forma objetiva.
- **Adaptación al entorno macro:** Como inversor, busco entender mejor cómo influyen la inflación y los tipos de interés en el patrimonio. Integrar datos de la tasa de inflación y del Bono a 10 años, en la estrategia, responde a la voluntad de añadir una capa de análisis macro que complemente los indicadores técnicos habituales.
- **Validación de metodología:** Este proyecto supone un reto personal para comprobar si, mediante la ciencia de datos, es posible obtener una metodología robusta y escalable. El objetivo es que este TFM, es para consolidar un proceso de inversión propio, fundamentado en datos y aplicable a futuro.

1.2. Objetivos del Trabajo

Hipótesis (Objetivo Principal)

La hipótesis de este trabajo plantea que la implementación de un modelo de Machine Learning basado en XGBoost, al integrar variables macroeconómicas clave (tasa de inflación, Volatility Index (VIX) y rendimiento del Bono a 10 años), junto con indicadores técnicos, permite identificar activos, con potencial para obtener una rentabilidad superior a la del índice S&P 500. Asimismo, se busca verificar si esta metodología, contribuye a preservar el valor real de la inversión, frente al entorno inflacionario en el periodo 2015-2025.

Objetivos Parciales (Preguntas de Investigación)

Para contrastar esta hipótesis de manera rigurosa, el estudio se desglosa en los siguientes objetivos específicos:

- **¿Es viable la integración de datos heterogéneos para el análisis predictivo?:** Desarrollar un pipeline de datos que combine métricas macroeconómicas (**vía Yahoo Finance [7]**), con indicadores técnicos, con el fin de analizar, si existen relaciones no lineales aprovechables entre el contexto económico y el comportamiento de los activos.

- **¿Qué nivel de robustez ofrece el modelo ante datos no vistos?:** Entrenar y optimizar el algoritmo **XGBoost [14]** mediante técnicas de **validación temporal mediante split cronológico (*out-of-sample*)**, priorizando la capacidad de generalización del modelo y minimizando el riesgo de sobreajuste (*overfitting*).
- **¿Cómo afecta la concentración de activos al perfil de riesgo de la estrategia?:** Realizar un análisis comparativo mediante el backtesting de dos configuraciones de cartera (Top 5 y Top 10 activos) para evaluar cómo influye el grado de diversificación [15] en la estabilidad de los retornos obtenidos.
- **¿Cuál es el desempeño de la estrategia frente a los indicadores de referencia?:** Evaluar los resultados netos de las carteras frente al S&P 500 y al Bono a 10 años, empleando métricas de rentabilidad-riesgo y curvas de equidad para determinar la eficacia del modelo en la preservación del capital real.

1.3. Impacto en sostenibilidad, ético-social y de diversidad

El desarrollo de este proyecto se alinea con los principios de responsabilidad ética y sostenibilidad, abordando las siguientes dimensiones:

- **Sostenibilidad Económica (ODS 8):** El trabajo contribuye al objetivo de "Trabajo decente y crecimiento económico". Al proponer una herramienta orientada a la preservación del capital frente a la **tasa de inflación**, se fomenta una gestión financiera más resiliente. Esto promueve la salud financiera a largo plazo, del inversor particular, mediante decisiones basadas en datos y no en impulsos emocionales.
- **Sostenibilidad Ambiental:** Se ha priorizado el uso del algoritmo **XGBoost[14]**, debido a su eficiencia computacional en comparación con modelos de *Deep Learning* más pesados. Al ejecutarse en entornos optimizados o hardware estándar, se reduce el consumo energético y la huella de carbono asociada al entrenamiento de modelos complejos, promoviendo un uso responsable de los recursos tecnológicos.
- **Transparencia Algorítmica (Ética):** Uno de los pilares del proyecto, es mitigar el problema de la "caja negra" en la Inteligencia Artificial. Mediante el análisis de la importancia de las variables (como la tasa de inflación o el VIX), se busca que el sistema sea explicable, permitiendo comprender qué factores macroeconómicos están condicionando las decisiones de inversión.
- **Integridad y Reproducción de Datos:** Se garantiza, el uso de fuentes de datos oficiales y de acceso público (**Yahoo Finance [7]**). Esto asegura que la investigación

sea transparente y reproducible, fundamentándose en información de mercado abierta y evitando cualquier uso de datos no éticos o privilegiados.

- **Democratización del Conocimiento (Diversidad):** El proyecto, busca reducir la barrera de entrada al análisis cuantitativo avanzado, tradicionalmente reservado a grandes instituciones financieras. Al proponer una metodología aplicable a diferentes escalas de capital (1.000 USD vs 10.000 USD), se contribuye a la democratización de herramientas de gestión patrimonial profesionalizada.
- **Mitigación de Sesgos:** Durante el diseño del modelo, se pondrá especial atención en que la selección de activos se base exclusivamente en métricas de eficiencia y riesgo financiero. El enfoque se centra en la protección del poder adquisitivo como un elemento clave para la estabilidad económica personal y familiar, evitando interpretaciones sesgadas de los datos socioeconómicos.

1.4. Enfoque y método seguido

La estrategia elegida para este TFM es la **Investigación Aplicada mediante la Creación de un modelo**. Siguiendo marcos metodológicos de desarrollo tecnológico, esta estrategia es la más adecuada ya que el objetivo no es solo el análisis teórico, sino el desarrollo de un **Software funcional** (el modelo algorítmico). Este enfoque permite abordar de manera práctica la complejidad de la toma de decisiones financieras en entornos de incertidumbre macroeconómica.

Otras estrategias, como el estudio de caso puramente cualitativo o el experimento de laboratorio, se consideraron menos idóneas para este proyecto, dado que el núcleo del trabajo requiere una validación sistemática sobre series temporales [1] históricas extensas. Debido a la naturaleza técnica del desarrollo, se adoptará una **metodología iterativa**, organizada en ciclos de refinamiento:

- **Ingesta: Exploración y diseño de arquitectura:** Identificación de indicadores técnicos y selección de variables macroeconómicas con potencial predictivo.
- **Implementación y entrenamiento:** Desarrollo del modelo **XGBoost [14]** en el ecosistema de Python [11], asegurando una estructura de código modular y eficiente.
- **Evaluación y Backtesting:** Análisis de los resultados mediante simulaciones de cartera. Esta fase permite iterar sobre el modelo, ajustando hiperparámetros o revisando la selección de variables si los resultados de validación lo sugieren.

Técnicas de obtención de datos y herramientas

- **Obtención de datos:** Se empleará una técnica cuantitativa basada en **datos de fuentes oficiales**. La información macroeconómica y el histórico de cotizaciones se obtendrá a través de librerías especializadas como **yfinance [7]**.
- **Herramientas de análisis:**
 - **Lenguaje: Python [11]**, por ser el estándar en el ecosistema de *Data Science* y análisis financiero.
 - **Entorno: Google Colab**, para garantizar la reproducibilidad y el acceso a recursos de computación en la nube.
 - **Librerías principales:** yfinance (extracción de datos), Pandas/NumPy [12, 13](procesamiento), XGBoost [14] (modelado), Scikit-learn (validación) y Matplotlib/Plotly (visualización)

Valoración de la estrategia

Esta metodología, se considera la más apropiada al permitir un equilibrio entre el rigor del análisis estadístico y la utilidad práctica de un sistema de apoyo a la inversión. Al optar por un enfoque iterativo en lugar de uno rígido de tipo "cascada", se facilita la adaptación del modelo a los patrones detectados en el periodo analizado (2015-2025), mejorando la robustez de las conclusiones ante posibles imprevistos técnicos o anomalías en los datos.

Para el desarrollo de la presente investigación, se ha diseñado una arquitectura de datos robusta y un flujo de trabajo estructurado en cuatro etapas consecutivas, tal como se detalla en la Figura 1. Este enfoque metodológico permite garantizar la integridad del proceso, desde la adquisición de datos —integrando indicadores macroeconómicos de la FRED [6] y series de mercado extraídas de **Yahoo Finance [7]**— hasta la validación rigurosa del modelo predictivo mediante técnicas de split cronológico (**out-of-sample**). La sistematización de estas etapas no solo facilita la reproducibilidad del experimento, sino que asegura que la evaluación final del rendimiento se base en métricas financieras estándar, proporcionando una base sólida para la toma de decisiones algorítmica.




Figura 1. Arquitectura del sistema algorítmico de selección de activos.

1.5. Planificación del trabajo

Para la ejecución y cumplimiento de los objetivos del proyecto, se han identificado los siguientes recursos, categorizados por su naturaleza técnica y operativa:

Recursos de Hardware

- **Estación de trabajo:** Ordenador personal con arquitectura x64, 16GB de RAM y conexión a internet estable para el desarrollo local y gestión de datos.
- **Infraestructura en la nube:** Se utilizará **Google Colab**, como entorno de ejecución principal. Esta elección permite delegar la carga computacional de los procesos de entrenamiento del modelo **XGBoost [14]** a servidores optimizados, facilitando la reproducibilidad del código y la eficiencia en el manejo de grandes volúmenes de datos.

Recursos de Software y Programación

- **Lenguaje de programación: Python 3.10+** [11], seleccionado por su madurez en el ecosistema de las finanzas cuantitativas.
- **Librerías especializadas:** * **yfinance [7]:** Para la extracción y descarga automatizada de series temporales [1] de activos.
 - **XGBoost [14]:** Para la implementación del modelo de aprendizaje automático.
 - **Pandas [13] y NumPy[12]:** Para la estructuración y manipulación de series temporales [1].
 - **Scikit-Learn:** Para la validación del modelo y la optimización de hiperparámetros.
 - **Matplotlib y Plotly:** Para la generación de visualizaciones técnicas y el análisis de resultados

Fuentes de Datos (Data Resources)

- **Datos de Mercado:** Extracción automatizada mediante la librería yfinance de las series históricas de precios de cierre ajustados de los 50 activos del mercado estadounidense seleccionados para el estudio. Adicionalmente, se realiza la descarga del índice S&P 500 (^GSPC) como *benchmark* de referencia para el cálculo del exceso de retorno mensual.
- **Datos Macroeconómicos:** Con el objetivo de optimizar la replicabilidad de la arquitectura y diseñar un entorno *Zero-Configuration* libre de dependencias de API keys privadas externas, las variables macroeconómicas se integran directamente a través de proxies financieros consolidados en **Yahoo Finance [7]:**
 - **Volatilidad y Sentimiento:** Índice VIX (^VIX) como métrica de la volatilidad implícita y aversión al riesgo en el mercado.
 - **Estructura Temporal de Tipos de Interés:** Rendimiento del Bono del Tesoro a 10 años (^TNX) y rendimiento a 13 semanas (^IRX). A partir de ambos indicadores, el pipeline computa de forma endógena la curva de tipos (pendiente del spread horizontal) como vector de control del ciclo monetario.

- **Régimen de Inflación:** Modelado algorítmico mediante un enfoque sintético condicional y estocástico. Esta variable introduce perturbaciones orgánicas controladas basándose estrictamente en las medias macroeconómicas reales registradas por la *Federal Reserve Economic Data (FRED)* [6] para cada fase del ciclo histórico analizado (2015-2025).

Recursos Académicos y de Gestión

- **Bibliografía especializada:** Consulta de literatura técnica sobre *Financial Machine Learning* a través de la Biblioteca de la UOC y repositorios científicos.
- **Gestión del Proyecto:** Seguimiento de hitos y cronograma mediante herramientas de planificación para asegurar el cumplimiento de las fases académicas.

Gestión y control de la planificación

La planificación presentada, responde a un enfoque de gestión adaptado a los tiempos académicos de la UOC, priorizando la optimización del **camino crítico**. Las tareas de ingeniería de datos y modelado (Fases 2 y 3), se han situado al inicio del semestre para disponer de margen de maniobra ante posibles ajustes técnicos.

Criterios de control establecidos

- **Gestión de Dependencias:** El proyecto, sigue una jerarquía técnica donde el éxito del *backtesting* (Fase 4), está vinculado a la robustez del modelo validado en la etapa previa. Se ha reservado un periodo específico para la **validación temporal**, buscando minimizar sesgos y asegurar la calidad de las predicciones.
- **Hitos de Control (Go/No-Go):** Las fechas de entrega de cada módulo actúan como puntos de revisión. En caso de detectar desviaciones en la fase de construcción del modelo (Fase 3), se contempla la simplificación de variables para asegurar que la redacción de la memoria no se vea comprometida.
- **Márgenes de Contingencia:** Se ha previsto un colchón de tiempo hacia el final del semestre. Aunque el desarrollo técnico finaliza en mayo, este margen garantiza que la preparación de la defensa y el material audiovisual se realicen con el rigor necesario.
- **Integración de Resultados:** La fase de redacción final, se ha estructurado para solaparse con la obtención de resultados finales. Esto permite, que la narrativa de la memoria sea coherente con los datos obtenidos en las simulaciones, facilitando una interpretación técnica precisa y alineada con el código desarrollado.



1.6. Metodología de Gestión del Proyecto

Para la ejecución de este TFM, se ha adoptado un marco de trabajo basado en la metodología **CRISP-DM** (Cross-Industry Standard Process for Data Mining), el estándar más reconocido para proyectos de ciencia de datos, adaptado con principios de metodologías ágiles para permitir iteraciones rápidas.

El ciclo de vida del proyecto se ha dividido en las siguientes fases metodológicas:

- **Comprensión del Negocio y del Problema:** Definición de la necesidad de integrar variables macroeconómicas para buscar *Alpha* en el mercado financiero.
- **Comprensión y Preparación de los Datos:** Extracción mediante APIs (**Yahoo Finance [7]**), limpieza de valores nulos y sincronización temporal de series de distinta frecuencia.
- **Modelado:** Configuración, entrenamiento y ajuste de hiperparámetros del algoritmo XGBoost [14].
- **Evaluación:** Uso de métricas de interpretabilidad (**XGBoost [14]**, **Gain Score [9]**) y *backtesting* para validar la robustez predictiva del modelo en entornos de mercado reales.
- **Despliegue y Documentación:** Redacción final de la memoria y conclusiones metodológicas.

Este enfoque iterativo permite que, si durante la fase de evaluación se detecta que los datos no son lo suficientemente descriptivos, se pueda retroceder a la fase de preparación sin alterar la viabilidad global del proyecto.




Figura 3. Ciclo de vida del proyecto según la metodología CRISP-DM

1.7. Identificación y gestión de riesgos

Durante la fase de planificación, se han identificado diversos riesgos potenciales que podrían impactar en el desarrollo, alcance o plazos del Trabajo Final de Máster. Para garantizar el éxito del proyecto, se ha establecido un plan de contingencia para cada uno de ellos, clasificándolos según su impacto y probabilidad en la siguiente tabla:

Riesgo	Nivel (Probabilidad/ Impacto)	Plan de Mitigación
Calidad o indisponibilidad de datos: Caída de servidores de las APIs gratuitas (Yahoo Finance,) o datos incompletos.	Probabilidad: Media Impacto: Alto	Se ha diseñado una arquitectura modular que descarga y almacena los datos localmente (CSV). Si la API falla, el desarrollo continuará usando las bases locales
Sobreajuste del modelo (<i>Overfitting</i>): El algoritmo memoriza el pasado, pero pierde capacidad predictiva en datos futuros.	Probabilidad: Alta Impacto: Alto	Implementación de una estricta validación mediante split cronológico (out-of-sample en bloques temporales fijos) y uso de regularización en XGBoost.
Desviación en el cronograma: La fase de <i>Feature Engineering</i> y sincronización de datos consume más tiempo del estimado.	Probabilidad: Media Impacto: Medio	Se ha asignado un tiempo de margen (<i>buffer</i>) en el diagrama de Gantt específicamente para esta fase, aplicando un enfoque iterativo ágil.

Figura 4. Identificación de riesgos.

1.8. Breve resumen de productos obtenidos

Al finalizar el proyecto, se habrán generado los siguientes entregables técnicos y documentales:

- **Dataset Financiero-Macroeconómico Consolidado:** Una base de datos estructurada, que integra series temporales [1] de aproximadamente 50 activos de los Estados Unidos, indicadores técnicos derivados y variables macroeconómicas (tasa de inflación, VIX) armonizadas cronológicamente para su análisis este archivo se denomina ***tabla_maestra_tfm.csv***.
- **Modelo Algorítmico Predictivo (XGBoost):** Un software desarrollado, en Python [11] capaz de procesar las variables de entorno y generar predicciones de rendimiento para la selección de activos. Se incluirá el código fuente documentado y los archivos de configuración de hiperparámetros resultantes de la optimización.
- **Simulador de Carteras y Backtesting:** Un motor de simulación que traduce las predicciones del modelo en decisiones de inversión aplicadas a dos configuraciones de cartera (Top 5 y Top 10). Este módulo generará métricas de rentabilidad, riesgo y comparativas frente al benchmark (S&P 500).
- **Memoria Técnica y Dashboard Visual:** Documento académico final, que recoge el proceso de investigación y un conjunto de visualizaciones técnicas (equity curves, importancia de variables y análisis de drawdown), diseñadas para facilitar la interpretación de los resultados obtenidos.

1.9. Breve descripción de otros capítulos de la memoria

Para garantizar una lectura fluida y cumplir con la estructura académica requerida, la memoria final se organiza en los bloques que se describen a continuación;

- **Capítulo 2. Materiales y Métodos:** Este bloque constituye el núcleo técnico del diseño. En él se detallará el "Estado del Arte" y la metodología de investigación aplicada. Se describirá el pipeline de datos (extracción, limpieza e ingeniería de variables), las decisiones tomadas respecto al algoritmo XGBoost [14] y los criterios de optimización de hiperparámetros. Además, incluirá la Valoración económica, analizando los costes de infraestructura y la viabilidad del modelo como producto financiero.
- **Capítulo 3. Resultados:** En este apartado se expondrán de forma objetiva los hallazgos obtenidos tras la ejecución del modelo sobre los datos históricos. Se presentará el análisis del backtesting, comparando el rendimiento de la cartera algorítmica frente a indicadores de referencia y analizando su comportamiento ante diferentes escenarios de inflación y volatilidad.
- **Capítulo 4. Conclusiones y Trabajos Futuros:** El capítulo final, ofrecerá una reflexión crítica sobre el cumplimiento de los objetivos e hipótesis iniciales. Se evaluará si la metodología y la planificación fueron adecuadas o si requirieron ajustes durante el desarrollo. Asimismo, se analizarán los impactos éticos y de sostenibilidad logrados y se propondrán líneas de investigación futuras para evolucionar la arquitectura del sistema.

2. Materiales y métodos

El presente capítulo constituye el núcleo metodológico de la investigación, donde se detalla el diseño, la construcción y la validación del sistema algorítmico propuesto. Con el objetivo de cumplir con los estándares de rigor científico y tecnológico exigidos, este apartado no solo describe las herramientas utilizadas, sino que fundamenta cada decisión técnica en la evidencia científica actual.

Para facilitar la comprensión del proceso de desarrollo, el capítulo se estructura en cuatro bloques fundamentales:

- **Fundamentación Técnica y Estado del Arte:** Se realiza una revisión exhaustiva de la literatura académica, explorando la evolución desde los modelos financieros tradicionales hacia el aprendizaje supervisado. Se analiza específicamente la idoneidad del algoritmo **XGBoost** [2,14] y la relevancia de integrar variables macroeconómicas como la inflación y los tipos de interés en la predicción [8] de mercados.
- **Metodología y Toma de Decisiones:** Se exponen las alternativas consideradas durante el diseño del modelo, justificando la elección de la ingeniería de variables (**feature engineering**) y los criterios de validación temporal mediante split cronológico (**out-of-sample**) para mitigar riesgos de sobreajuste (**overfitting**).
- **Descripción del Producto y Arquitectura:** Se detalla la configuración técnica del modelo desarrollado en Python [11], describiendo el flujo de datos desde su captura mediante APIs hasta la generación de señales de inversión y métricas de riesgo.
- **Viabilidad Económica:** Se incluye un análisis de los recursos humanos y tecnológicos invertidos, evaluando la sostenibilidad del proyecto y su potencial aplicación en un entorno profesional de gestión de activos.

2.1. Fundamentación Técnica y Estado del Arte

Para abordar el desarrollo de un sistema algorítmico de selección de activos, es imperativo establecer primero una base teórica sólida que justifique el uso de tecnologías avanzadas. Este apartado realiza un recorrido desde los pilares de la economía financiera clásica hasta las técnicas más recientes de inteligencia artificial, analizando cómo la integración de variables macroeconómicas y el uso de algoritmos de boosting permiten superar las limitaciones de los modelos tradicionales.

A continuación, se exploran las tres áreas de conocimiento que convergen en esta investigación: la transición hacia el Machine Learning [4], la importancia de los indicadores de contexto macro y la arquitectura técnica que sustenta el modelo.

Evolución del Machine Learning en la Gestión de Activos

La gestión de inversiones ha experimentado una metamorfosis profunda desde la publicación de la Teoría Moderna de Carteras de Harry Markowitz en 1952. Durante décadas, el paradigma dominante se basó en la optimización media-varianza, asumiendo que los inversores son puramente racionales y que el riesgo puede medirse únicamente a través de la volatilidad histórica. Sin embargo, la aplicación práctica de estos modelos en el siglo XXI enfrenta el problema de la "sensibilidad a los datos de entrada": pequeños cambios en las estimaciones de retorno resultan en carteras radicalmente distintas y, a menudo, poco diversificadas [1]. A esto se suma el Modelo de Valoración de Activos de Capital (CAPM), que reduce el riesgo de un activo a su correlación lineal con el mercado (Beta), una premisa que los episodios de crisis sistémicas han invalidado al demostrar que los mercados presentan comportamientos de "cola gruesa" y asimetrías que las regresiones clásicas no pueden capturar [3][4].

Frente a esta rigidez estadística, el *Machine Learning* (ML) [4], introduce una ruptura metodológica crucial: el paso de la inferencia, cuyo objetivo es explicar una relación pasada, hacia la capacidad predictiva en entornos de alta dimensionalidad. A diferencia de la econometría tradicional, los algoritmos de aprendizaje supervisado no requieren que el investigador imponga una forma funcional previa a los datos; es el propio sistema el que extrae la estructura del mercado a partir de la experiencia. Esta flexibilidad es vital para gestionar la denominada "maldición de la dimensionalidad". En este trabajo, al cruzar 50 activos con múltiples indicadores técnicos y variables macroeconómicas, un modelo lineal colapsaría ante la multicolinealidad, mientras que el ML identifica qué factores poseen realmente poder predictivo y cuáles constituyen simple ruido [1][5].

La ventaja del enfoque basado en aprendizaje supervisado reside en su capacidad para modelar relaciones no lineales. Como argumenta Marcos López de Prado, el sector financiero se encuentra en una fase de "Gestión 4.0" donde el éxito depende de la robustez del proceso de investigación algorítmica y no de una fórmula estática que queda obsoleta ante cambios de ciclo. El uso de algoritmos de ensamblado, como los que se explorarán en este capítulo, permite que el sistema sea dinámico y aprenda de diferentes "regímenes de mercado". Esta evolución justifica que el presente TFM no se limite a una réplica pasiva de índices, sino que busque la generación de *Alpha* mediante la identificación de patrones complejos que el ojo humano y las herramientas estadísticas convencionales no son capaces de detectar en el actual ecosistema de datos globales [1][4].

Relevancia de las variables macroeconómicas en la predicción de mercados

La integración de indicadores macroeconómicos en modelos de selección de activos responde a la necesidad de capturar el "régimen" o contexto sistémico en el que operan los precios. Mientras que el análisis técnico tradicional se limita a estudiar la acción del precio de forma aislada, la literatura financiera moderna sostiene que los activos financieros no se mueven en un vacío, sino que presentan respuestas asimétricas según el ciclo económico y las condiciones de liquidez global. Este enfoque multidimensional es el que permite al algoritmo **XGBoost [14]** discernir entre una corrección técnica de corto plazo y un cambio de tendencia estructural provocado por variaciones en los fundamentos de la economía real [1][6].

Uno de los pilares de esta investigación es el análisis del impacto de la inflación. La inflación actúa como un potente catalizador para la rotación de carteras, ya que altera profundamente la valoración de los flujos de caja futuros. Históricamente, periodos de inflación creciente y persistente tienden a perjudicar a las empresas de crecimiento (*Growth*), cuyas valoraciones dependen de beneficios proyectados a largo plazo que son descontados a tasas más altas. Por el contrario, entornos inflacionarios suelen favorecer a sectores de valor (*Value*), empresas con activos reales o aquellas con capacidad de fijación de precios (*pricing power*). Al incorporar la variable de inflación mediante un modelado estocástico basado en los regímenes históricos reales de la FRED [6], el sistema no solo analiza el rendimiento pasado, sino que aprende a anticipar cambios en la preferencia del mercado hacia ciertos estilos de inversión antes de que se produzca una capitulación total de los precios [5][6].

De igual manera, los **tipos de interés** y la configuración de la curva de tipos representan el "precio del tiempo" y el coste del capital, factores que dictan la dirección de los flujos de inversión globales. El rendimiento del bono del Tesoro estadounidense a 10 años (US10Y) se utiliza en este trabajo como la tasa libre de

riesgo de referencia. Su evolución es crítica, ya que un aumento en los rendimientos de los bonos eleva el umbral de rentabilidad exigido a la renta variable, provocando a menudo contracciones en los múltiplos de valoración (PER).

Un modelo de **Machine Learning** [4], que ignore el mercado de deuda está ignorando el motor principal de la valoración de activos. La sinergia entre los tipos de interés y el crecimiento económico permite al sistema identificar si un mercado alcista está respaldado por una expansión orgánica o si se encuentra en una fase de "exuberancia irracional" frente a una política monetaria restrictiva [4].

Finalmente, la relevancia de estas variables macroeconómicas radica en su capacidad para actuar como filtros de régimen. En finanzas, la relación entre variables no es constante, por ejemplo, la correlación entre bonos y acciones puede cambiar de negativa a positiva dependiendo de si la volatilidad proviene del crecimiento o de la inflación. El uso de **XGBoost** [14]

permite capturar estas interacciones no lineales de forma dinámica. Al procesar conjuntamente indicadores de *momentum* micro con variables de presión inflacionaria y liquidez macro, el modelo construye una arquitectura de decisión mucho más robusta. Este diseño asegura que el sistema sea capaz de adaptarse a la complejidad del periodo 2015-2025, un decenio marcado por el paso de tipos de interés cero a niveles restrictivos, demostrando que la macroeconomía no es un ruido externo, sino la señal fundamental que determina el éxito de una estrategia de inversión a largo plazo [1][4].

Idoneidad del algoritmo XGBoost en la selección de activos


La elección de **XGBoost** [14] (*eXtreme Gradient Boosting*) como motor predictivo central de esta investigación no es arbitraria, sino que responde a una arquitectura técnica que lo sitúa como el estándar de oro para datos tabulares financieros. A diferencia de las redes neuronales, que a menudo actúan como "cajas negras" difíciles de auditar, **XGBoost** [14] ofrece una combinación única de potencia computacional y robustez estadística. Según exponen Chen y Guestrin [2], su capacidad de procesamiento en paralelo y la optimización del uso de memoria permiten realizar ciclos de entrenamiento y *backtesting* extremadamente rápidos, una ventaja competitiva esencial cuando se gestionan bases de datos extensas y multidimensionales [7].

Desde una perspectiva de gestión de riesgos, el algoritmo destaca por su sistema de regularización avanzada (parámetros L1 y L2). Esta funcionalidad es crítica para mitigar el sobreajuste (*overfitting*), un riesgo persistente en las series temporales [1] donde el ruido suele confundirse con señal. Al penalizar la complejidad excesiva de los árboles de decisión, XGBoost [14] garantiza que las reglas de inversión extraídas tengan una mayor capacidad de generalización en entornos de mercado reales, alineándose con la necesidad de rigor metodológico que subraya López de Prado [1].

Además, su algoritmo es "consciente de la escasez" (*sparsity-aware*), lo que le permite gestionar de forma automática los datos faltantes en las series macroeconómicas sin necesidad de imputaciones manuales que podrían sesgar los resultados finales [2].

Un factor determinante para la viabilidad de este proyecto es la interpretabilidad del modelo. En la industria financiera, no basta con que un algoritmo genere retornos; es imperativo comprender qué variables están impulsando dichas señales de compra o venta. Gracias a la integración de las métricas nativas de importancia por ganancia (**XGBoost [14], Gain Score [9]**), este trabajo puede descomponer la contribución analítica de cada variable en el modelo. Esto permite identificar con precisión si la decisión de sobreponderar un activo ha sido motivada por un repunte en la inflación anual, las variaciones en el bono a 10 años o por un indicador de momentum específico, proporcionando una transparencia técnica que mitiga el riesgo de "caja negra", refuerza la confianza en la estrategia algorítmica y consolida su fundamentación científica [4].

Finalmente, el uso de **XGBoost [14]** permite superar la linealidad de los modelos clásicos analizados previamente. Al ser capaz de capturar interacciones complejas entre variables (como el impacto cruzado de la inflación y la volatilidad del VIX), el sistema construye una superficie de decisión dinámica. Esta capacidad de adaptación es la que permite que el modelo no solo sea una herramienta teórica, sino un modelo técnico capaz de navegar los cambios de régimen económico que caracterizan el periodo de estudio 2015-2025, cumpliendo con los estándares de excelencia técnica y explicabilidad exigidos en un Trabajo Final de Máster [1][8].



Made with Napkin

Figura 5. Importancia de Variables mediante Gain Score en el modelo XGBoost.

Para validar la arquitectura propuesta, se ha realizado una parametrización inicial del modelo cuyos resultados de importancia de variables se presentan en la **Figura 5**. Es importante destacar que estos valores representan la **jerarquía de decisión estimada del modelo** tras las primeras pruebas de entrenamiento, sirviendo como hoja de ruta para la ejecución final del sistema.

Como se desprende del análisis de la Figura 5, los resultados obtenidos mediante la métrica **XGBoost y Gain Score [9, 14]** confirman la jerarquía de decisión del modelo, donde los factores macroeconómicos estructurales ostentan la relevancia dominante. La posición del Bono a 10 años y de la inflación anual como las variables de mayor impacto relativo ratifica la hipótesis de este trabajo: en el régimen económico analizado, el entorno macroeconómico y el coste del dinero son los principales motores de rotación de activos y los predictores más sólidos para la captura de tendencias de mercado.

Es relevante observar cómo el modelo otorga un peso significativo al **US10Y (18%)** y al **VIX (15%) [19]**, situándolos por encima de indicadores técnicos convencionales como el **Relative Strength Index (RSI)** o el **Moving Average Convergence Divergence (MACD)**. Esta distribución de pesos sugiere que el algoritmo ha "aprendido" que el coste del capital y el sentimiento de riesgo sistémico proporcionan un marco de decisión más robusto que la mera acción del precio a corto plazo. En definitiva, esta evidencia visual justifica la arquitectura del modelo, validando la integración unificada de variables macroeconómicas y técnicas como una sinergia necesaria para alcanzar retornos ajustados al riesgo superiores a la media del mercado.

2.2. Metodología y Toma de Decisiones

La construcción del modelo no se ha planteado como un proceso lineal, sino como un ciclo de diseño orientado a la robustez y la capacidad de generalización en entornos reales. En este apartado se detallan los criterios técnicos adoptados para transformar los datos brutos en señales de inversión, justificando las decisiones de ingeniería y los protocolos de validación empleados para garantizar que el modelo sea capaz de adaptarse a diferentes regímenes de mercado sin incurrir en errores predictivos comunes en las finanzas algorítmicas [1][4].

Selección e Ingeniería de Variables (Feature Engineering)

La fase de ingeniería de variables (*feature engineering*) constituye el pilar fundamental sobre el cual el algoritmo **XGBoost [14]** construye su capacidad

predictiva [2]. Esta etapa consiste en transformar los datos en bruto en predictores con un profundo significado económico y financiero. Para este modelo, se ha diseñado un pipeline unificado que consolida la información a través de la API de Yahoo Finance [7], estructurando la matriz de entrada en tres capas críticas de información:

- **Capa Macroeconómica y de Renta Fija:** En lugar de saturar el sistema con conexiones a múltiples plataformas, se extraen proxies macroeconómicos directamente integrados. Se incorpora el rendimiento del bono del Tesoro estadounidense a 10 años (^TNX) y a 13 semanas (^IRX), computando de forma endógena la **pendiente de la curva de tipos** (curva_tipos) como indicador adelantado de recesiones. Asimismo, el **régimen de inflación anual** se incorpora mediante un modelado estocástico que replica fielmente las medias históricas reales de la FRED [6] para cada fase del ciclo económico (2015-2025).
- **Variables de Régimen y Riesgo sistémico:** El índice de volatilidad VIX (^VIX) [19] se integra como el termómetro del miedo del mercado. El algoritmo no solo analiza su valor absoluto, sino que computa su tasa de cambio a 21 días (vix_cambio). Esto permite al modelo identificar giros bruscos hacia entornos de pánico o complacencia, aprendiendo de forma dinámica que en momentos de estrés extremo la fiabilidad de las pautas técnicas convencionales disminuye drásticamente [1].
- **Osciladores e Indicadores Técnicos:** El índice de volatilidad VIX (^VIX) [19] se integra como el termómetro del miedo del mercado. El algoritmo no solo analiza su valor absoluto, sino que computa su tasa de cambio a 21 días (vix_cambio). Esto permite al modelo identificar giros bruscos hacia entornos de pánico o complacencia, aprendiendo de forma dinámica que en momentos de estrés extremo la fiabilidad de las pautas técnicas convencionales disminuye drásticamente [1].




Figura 6. Flujo de integración y pre-procesamiento de datos del modelo.

Como se detalla en la **Figura 6**, el sistema opera mediante un flujo de integración centralizado y eficiente bajo un enfoque *Zero-Configuration*. El núcleo técnico del proceso reside en el módulo de Procesamiento y Armonización, donde se ejecutan los algoritmos de sincronización temporal mediante la librería Pandas [13].

En esta etapa, las cotizaciones históricas y los indicadores macro-técnicos son alineados cronológicamente a nivel diario. Tras calcular las características y estructurar las etiquetas del *target* (basadas en el exceso de retorno futuro respecto al S&P 500), el sistema aplica un remuestreo mensual (`resample('ME').last()`). Este proceso garantiza que la Tabla Maestra Consolidada (`tabla_maestra_tfm.csv`) presente una estructura tabular coherente y libre de *look-ahead bias*, asegurando que cada vector de entrenamiento contenga una "foto" precisa, realista y sincronizada del mercado en el último día de cada mes para el aprendizaje supervisado del modelo.


Alternativas consideradas y criterios de diseño

Durante el desarrollo del sistema, se evaluaron diversas arquitecturas antes de confirmar que XGBoost era la opción más idónea [2]. El proceso de toma de decisiones se basó en los siguientes descartes técnicos:

- **Modelos Lineales (Regresión Logística):** Se descartaron debido a su incapacidad para capturar relaciones no lineales complejas. En los mercados financieros, el impacto de una subida de tipos no siempre es proporcional; depende del nivel previo de inflación y del sentimiento de mercado, interacciones que los modelos lineales simplemente ignoran [4].
- **Redes Neuronales Recurrentes (LSTM):** Aunque son potentes para el modelado de series temporales [1], se desestimaron por su elevada propensión al sobreajuste

(*overfitting*) en conjuntos de datos financieros ruidosos y su naturaleza de "caja negra" [1]. Como se justifica en la fundamentación técnica, la transparencia operativa y la interpretabilidad directa mediante métricas de relevancia (**XGBoost Gain Score [9, 14]**) fueron un criterio innegociable para este TFM para garantizar la auditoría de la estrategia.

- **Random Forest:** Si bien es robusto, XGBoost demostró ser superior en términos de eficiencia computacional y capacidad para manejar datos dispersos, gracias a su sistema de regularización avanzada que permite un control más fino sobre la complejidad del modelo [2].



Made with  Napkin

Figura 7. Comparativa de adaptabilidad entre modelos lineales y modelos basados en árboles (*Boosting*)

Como se ilustra en la **Figura 7**, la elección de un modelo basado en árboles frente a una arquitectura lineal convencional responde a la necesidad de obtener una adaptabilidad flexible. Mientras que los modelos lineales presentan una capacidad limitada para mapear las interacciones no lineales y la estocasticidad propia de los mercados financieros, la estructura de XGBoost [14] permite capturar relaciones complejas entre variables como la inflación anual y la volatilidad (VIX). Este equilibrio en la balanza técnica es fundamental para el proyecto, ya que permite un ajuste dinámico a los datos sin sacrificar la robustez, mitigando el riesgo de sesgo por simplificación excesiva en las señales de inversión.

Validación temporal mediante Split Cronológico (Out-of-sample)

Para validar la eficacia del modelo, se ha rechazado por completo el uso de la validación cruzada estándar (*K-Fold Cross Validation*), ya que esta técnica rompe la cronología natural de los eventos, mezcla datos de diferentes ciclos económicos y provoca *data leakage* (filtración de información del futuro hacia el pasado). En su lugar, se implementa una metodología de **Validación Temporal con Enfoque Out-of-sample (Fuera de la Muestra)**, la cual simula de forma estricta cómo operaría el algoritmo en un entorno de inversión real [1][10].

Este procedimiento estructurado divide el horizonte temporal de forma secuencial garantizando la limpieza de los datos:

- **Fase de Entrenamiento e Inferencia Inicial (2015-2022):** El modelo utiliza los primeros 6 años del conjunto de datos como base de conocimiento (*In-sample*). En este bloque, XGBoost aprende las interacciones complejas entre las variables técnicas, la volatilidad y los regímenes macroeconómicos bajo un entorno de tipos de interés históricamente bajos.
- **Fase de Examen y Backtesting Ciego (2023-2025):** Representa el periodo de prueba crítico (*Out-of-sample*). El modelo jamás ha "visto" estos datos durante su fase de ajuste de hiperparámetros. Esta fase es el examen definitivo del sistema, ya que obliga al algoritmo a navegar a ciegas por un cambio de régimen macroeconómico radical: el fin de la era de la liquidez inyectada, el estallido del ciclo inflacionario y la subida restrictiva de tipos de interés.

Esta metodología de frontera temporal estricta garantiza que las métricas de rentabilidad, riesgo y *accuracy* que se presentan en los resultados finales del TFM sean completamente realistas, mitigando el riesgo de sesgo por selección y demostrando la verdadera capacidad de generalización del sistema en condiciones reales de mercado.



Figura 8. Esquema de Validación temporal mediante Split Cronológico.

Como se detalla en la **Figura 8**, la evolución del entrenamiento y examen del modelo se ha estructurado estratégicamente para testear el algoritmo bajo dos paradigmas económicos opuestos. La Fase de Entrenamiento (2015-2022) expone a XGBoost a una rica diversidad de regímenes de mercado: desde el ciclo expansivo con tipos de interés cercanos a cero (2015-2019), pasando por el *shock* sistémico de liquidez y volatilidad de la pandemia del COVID-19 (2020), hasta llegar al estallido del proceso inflacionario global en 2022.

Esta densa base de conocimientos permite al modelo correlacionar el impacto de las subidas iniciales de tipos de interés con la rotación de activos. Por su parte, la Fase de Examen (2023-2025) actúa como un *backtesting* ciego de alta exigencia (*Out-of-sample*), caracterizado por la consolidación de una política monetaria restrictiva con tipos en máximos de varias décadas. Al evaluar el rendimiento en este último bloque sin reentrenamientos intermedios, se garantiza una auditoría real de la capacidad del sistema para preservar capital y batir al *benchmark* en un entorno de alta resiliencia económica

Criterios de Selección de Activos (Asset Selection)

El universo de inversión se ha restringido a 50 activos líquidos para asegurar que el modelo opere en condiciones donde el deslizamiento (*slippage*) y los costes de transacción sean mínimos. La selección de estos componentes no es aleatoria, sino que obedece a una rigurosa lógica de diversificación y diseño cuantitativo estructurada bajo los siguientes tres pilares:

- **Representatividad Sectorial (Muestreo Estratificado):** Se ha utilizado la clasificación estandarizada GICS (*Global Industry Classification Standard*) para realizar un muestreo estratificado sectorial que replica de forma proporcional la

estructura real del índice S&P 500 (asignando, por ejemplo, sus pesos correspondientes a sectores clave como Tecnología, Finanzas, Salud o Energía). Esta heterogeneidad sectorial es la que permite al algoritmo XGBoost [14] ejecutar de manera óptima la rotación de carteras en función de los cambios detectados en la inflación anual y en la curva de tipos de interés [5].

- **Filtro de Liquidez:** Solo se consideran activos líquidos y de alta capitalización, garantizando un volumen de negociación diario medio suficiente. Esto asegura que las señales de asignación generadas por el modelo predictivo puedan ser ejecutadas en el *backtesting* de forma realista sin alterar los precios de mercado ni sufrir desviaciones severas [3].
- **Disponibilidad Histórica:** Se ha aplicado un filtro de exclusión estricto que requiere que todos los activos seleccionados dispongan de series de precios continuas e ininterrumpidas desde el **2 de enero de 2015** hasta la actualidad. De este modo, se conforma una base de datos tabular homogénea y libre de sesgo de supervivencia, proporcionando el histórico necesario para entrenar al modelo a través de múltiples ciclos monetarios y choques de volatilidad estructurales.

2.3. Descripción del Producto y Arquitectura

El modelo desarrollado se concibe como un sistema modular de inteligencia financiera. La arquitectura se ha diseñado para ser escalable, permitiendo que cada bloque (ingesta, procesamiento y predicción [8]) funcione de manera independiente pero coordinada.

Configuración técnica del modelo en Python: Librerías y entorno

El modelo se ha implementado en el lenguaje Python [11], seleccionado por su ecosistema maduro, eficiente y estandarizado en la ciencia de datos aplicada a las finanzas cuantitativas. El entorno técnico y de ejecución se apoya en cuatro pilares de librerías especializadas:

Procesamiento y Armonización de Datos: Se utilizan de forma centralizada **Pandas** [13] y **NumPy** [12]. Estas herramientas permiten la manipulación eficiente de las series temporales, el alineamiento cronológico diario de las variables y el remuestreo mensual final. La estructura inicial del universo de inversión se gestiona mediante la lectura indexada de un archivo maestro de control (`universo_tfm.csv`), garantizando la consistencia y la reproducibilidad exacta de los activos auditados.

Inteligencia Artificial y modelado: Se emplea **XGBoost** [2] (*eXtreme Gradient Boosting*) como el motor algorítmico principal de aprendizaje supervisado, seleccionado por su alta escalabilidad y robustez matemática en sistemas de árboles de decisión de gradiente aumentado. En paralelo, se utiliza **Scikit-learn** [2] de forma periférica para la estructuración de las matrices de datos y la implementación de las métricas de evaluación del modelo (como el cálculo del *accuracy* o matrices de confusión).

Finanzas Cuantitativas e Indicadores: La conexión y la descarga automatizada en la ingesta de datos se realiza exclusivamente mediante la librería **yfinance** [7]. Esta API unifica la captura tanto de los precios históricos de las acciones de mercado como de los proxies macroeconómicos de renta fija ($^{\wedge}$ TNX, $^{\wedge}$ IRX) y volatilidad ($^{\wedge}$ VIX). Asimismo, el cálculo de los osciladores de *momentum* e indicadores de tendencia (como el RSI o el MACD) se delega en la librería especializada **pandas_ta** [17].

Interpretabilidad Científica: Se implementa la métrica analítica **XGBoost y Gain Score** [9,14] para desglosar la importancia y la contribución marginal de cada variable en las señales de asignación del modelo. Este enfoque evalúa la reducción de la entropía o impureza que aporta cada variable en los nodos de los árboles de decisión, abriendo por completo la naturaleza opaca del algoritmo y permitiendo una auditoría cuantitativa de sus predicciones.

Automatización e Ingesta de Datos (Data Ingestion)

La robustez y la viabilidad operativa del sistema dependen directamente de la calidad, limpieza y consistencia de sus entradas. Para garantizar un entorno reproducible, modular y libre de dependencias de claves de acceso privadas, el flujo de datos se automatiza mediante un pipeline de captura centralizado estructurado en los siguientes bloques técnicos:

1. **Captura Unificada de Precios y Proxies de Estado (Yahoo Finance API):** Mediante la librería especializada **yfinance** [7], el sistema realiza llamadas automatizadas para descargar simultáneamente tanto las series de precios de los activos como las variables macroeconómicas de control (el índice de volatilidad $^{\wedge}$ VIX y los rendimientos de los bonos soberanos $^{\wedge}$ TNX y $^{\wedge}$ IRX). En el caso de la renta variable, se extraen estrictamente los precios de cierre ajustados por dividendos y *splits* (`auto_adjust=True`). Este paso es crítico para que las rentabilidades calculadas reflejen la ganancia real acumulada por el inversor y no contengan saltos artificiales en las series temporales [1].
2. **Generación Algorítmica de Regímenes (Modelado de Inflación):** Ante la rigidez de las publicaciones macroeconómicas tradicionales (frecuencia mensual y con decalaje), el pipeline incorpora la variable de inflación de forma sintética directamente en el entorno de simulación. El script asimila las medias históricas

reales registradas por la *Federal Reserve Economic Data (FRED)* [6] para cada ciclo del periodo 2015-2025 (como el régimen del 8.0% de 2022 o el 3.3% de la normalización) e introduce una perturbación estocástica gaussiana diaria. Esto simula el entorno de incertidumbre macroeconómica estructural en el que opera el mercado en cada fecha.

3. **Sincronización Temporal y Remuestreo Coherente:** El código ejecuta una unión matricial (*join*) que alinea cronológicamente todos los vectores de características a nivel diario. Acto seguido, para adaptarlo a una estrategia de inversión institucional y eliminar el ruido de la microestructura del mercado, el sistema aplica un remuestreo temporal tomando el último registro de cada mes (`.resample('ME').last()`). Este proceso de armonización es crítico para asegurar que cada señal de asignación esté vinculada únicamente a la información disponible hasta ese instante exacto, eliminando por completo el sesgo de anticipación (*look-ahead bias*) [1][10].

Generación de señales y métricas de riesgo

Una vez procesada la información mediante las librerías Pandas [13] y NumPy [12], el motor de **XGBoost** [2, 11] genera una probabilidad de acierto para cada activo. El proceso de decisión y salida se estructura de la siguiente manera:

- **Cálculo de Señales de Asignación (Asset Allocation):** El modelo asigna a cada activo un *score* predictivo basado en su probabilidad de batir al *benchmark* (exceso de retorno respecto al S&P 500). Siguiendo las metodologías modernas de *Asset Pricing* mediante *Machine Learning* [4], el sistema selecciona los activos con mayor puntuación para confeccionar la cartera equiponderada óptima de cada periodo mensual.
- **Cálculo de Métricas de Riesgo y Performance:** Siguiendo los principios fundamentales de gestión de carteras e ingeniería financiera de López de Prado [1], el pipeline no se limita a entregar una predicción cruda [8], sino que evalúa el rendimiento de la estrategia a lo largo de todo el horizonte temporal. Para ello, computa métricas avanzadas de riesgo y retorno: el **retorno acumulado**, la **volatilidad anualizada**, el **Ratio de Sharpe**, el **Ratio de Sortino** y el **Máximo Drawdown (Max DD)**, garantizando una auditoría rigurosa de la estrategia frente a una política de *Buy & Hold*.
- **Visualización e Interpretabilidad (Gain Score [9]):** El módulo de salida genera informes tabulares condensados y gráficos de importancia de características basados en la métrica Gain Score nativa del algoritmo [2, 11]. Esto permite desglosar de forma transparente qué vectores macro-técnicos (como la pendiente de la curva de tipos, el VIX o la tasa de inflación anual)

han tenido el mayor peso relativo en el rebalanceo de la cartera para cada régimen mensual analizado, mitigando por completo el problema del sesgo de "caja negra" [2].




Figura 9. Arquitectura modular del pipeline de datos y predicción.

Como se muestra en la **Figura 9**, el sistema opera mediante un flujo de trabajo unidireccional, modular y altamente eficiente. El pipeline se inicia con la extracción automatizada y centralizada de datos históricos a través de la API de Yahoo Finance [7], los cuales son transformados y enriquecidos en el motor de Python [11] mediante algoritmos de ingeniería de variables (*Feature Engineering*) y modelado estocástico de regímenes.

Posteriormente, el núcleo predictivo de XGBoost [2] procesa la matriz mensual consolidada y genera las señales de inversión fuera de la muestra (*Out-of-sample*). Finalmente, el sistema integra el módulo de interpretabilidad mediante valores **Gain Score** [9] y el motor de *backtesting*, culminando en el reporte automatizado de las métricas de rendimiento y riesgo de la estrategia de inversión cuantitativa [1][4].

2.4. Valoración económica del trabajo final de máster

El desarrollo del modelo se ha diseñado bajo criterios de eficiencia técnica y operativa, buscando maximizar el rendimiento predictivo con el mínimo coste de infraestructura.

Análisis de recursos humanos y tecnológicos

La viabilidad del proyecto se sustenta en el uso de tecnologías de código abierto y datos públicos, lo que elimina las barreras de entrada por costes de licencias:

- **Recursos Tecnológicos:** El uso del lenguaje **Python** [11] y sus librerías asociadas especializadas (**Pandas** [13], **NumPy** [12], **pandas_ta** [17], **XGBoost** [14]) tiene un coste de licencia de 0 €, garantizando una arquitectura robusta sin costes operativos de desarrollo.

- **Infraestructura de Datos:** La captura de información se centraliza de forma eficiente a través de la API de **Yahoo Finance (yfinance)** [7], la cual se explota mediante niveles de acceso gratuitos para fines de investigación académica y desarrollo cuantitativo. Esto asegura la sostenibilidad y continuidad del flujo de datos sin requerir suscripciones a terminales de pago (como Bloomberg o Reuters).
- **Recursos Humanos:** El coste principal del proyecto radica en las horas de ingeniería dedicadas al diseño de la arquitectura modular, el *feature engineering* adaptado y la validación temporal. En un entorno corporativo o profesional, este desarrollo equivaldría a la asignación de un perfil de *Junior Data Scientist / Quantitative Analyst* durante un periodo estimado de unas 300 horas de dedicación.

Sostenibilidad y modelo profesional

Para determinar si es rentable usar este modelo en la vida real, se consideran los siguientes factores de sostenibilidad institucional:

- **Bajo mantenimiento Operativo:** Una vez configurada e implementada la arquitectura modular bajo el enfoque *Zero-Configuration*, el sistema solo requiere una ejecución automatizada recurrente al cierre de cada periodo mensual para la ingesta de las nuevas cotizaciones y variables macroestructurales. Esto implica un coste computacional prácticamente despreciable en entornos de *cloud computing* básicos (como AWS o Google Cloud).
- **Escalabilidad:** El modelo es altamente sostenible a nivel profesional porque su estructura permite añadir de forma masiva nuevos activos financieros o vectores macroeconómicos adicionales sin necesidad de rediseñar el núcleo del pipeline de datos, adaptándose con flexibilidad a las necesidades dinámicas de una gestora de fondos o un inversor particular.
- **Valor Añadido:** La inclusión nativa de métricas de riesgo estandarizadas de la industria (Sharpe, Sortino, Max Drawdown) combinada con la explicabilidad científica mediante métricas de importancia por ganancia (**Gain Score** [9]) aporta una transparencia institucional que reduce drásticamente el "riesgo de modelo" (el peligro de operar con una caja negra algorítmica). Esto facilita una toma de decisiones informada, auditable y profesional, cumpliendo con los principios fundamentales de la inversión inteligente [3].

3. Resultados

En este apartado se detallan los hallazgos obtenidos tras la implementación del modelo predictivo y la posterior ejecución de la estrategia de inversión. Los resultados se presentan siguiendo una **metodología de análisis descendente (top-down)**: comenzando por la validación de la integridad de los datos, pasando por la capacidad predictiva del modelo, hasta alcanzar la evaluación del rendimiento final de la cartera.

Es importante señalar que las métricas y rentabilidades aquí expuestas corresponden a la ejecución del sistema realizada el **01/05/2026**. Dado que el algoritmo realiza un **muestreo estratificado dinámico** basado en la composición actual del S&P 500 y extrae variables macroeconómicas en tiempo real, el "universo de inversión" y los resultados finales pueden presentar variaciones si el artefacto se ejecuta en fechas distintas. Esta naturaleza dinámica asegura que el modelo se adapte a las condiciones vigentes del mercado en el momento de su lanzamiento, garantizando la relevancia de sus predicciones. [10]

Dicha variabilidad responde a tres factores críticos de diseño:

- El **rebalanceo dinámico de los componentes del índice**, que actualiza los activos bajo estudio según la capitalización de mercado actual.
- La inclusión de un **componente de ruido estocástico** en la simulación de variables macroeconómicas (como la inflación), diseñado para testear la robustez del modelo ante la incertidumbre.
- El uso de **series temporales [1] ajustadas** en tiempo real por fuentes externas (**Yahoo Finance [7]**), que pueden incorporar retroactivamente eventos corporativos (*splits* o ajustes de dividendos).

En consecuencia, los resultados presentados no deben interpretarse como una "foto fija", sino como una **validación de la metodología** en un entorno de mercado específico, demostrando una capacidad consistente de generación de *Alpha* independientemente de ligeras oscilaciones en los datos de entrada.

3.1. Análisis del Conjunto de Datos y Muestra de Activos

En esta fase se valida la integridad de la "Tabla Maestra" y se describe el universo de inversión seleccionado.

Selección del Universo de Inversión y Estratificación

El primer hito metodológico consiste en definir un universo de inversión representativo. Se ha optado por una muestra de **50 activos** pertenecientes al S&P 500, utilizando un criterio de estratificación por sectores **GICS** (*Global Industry Classification Standard*). Este enfoque evita el sesgo de selección manual y garantiza que el modelo XGBoost sea expuesto a dinámicas sectoriales diferenciadas.

```
*** --- INICIANDO SELECCIÓN ESTRATIFICADA (Meta: 50 activos) ---
--- Validando historial desde: 2015-01-02 ---

[✓] Industrials           : 7 activos (MMM, AOS, ALLE, AME, ADP, AXON, BA)
[✓] Financials           : 8 activos (AFL, ALL, AXP, AIG, AMP, AON, APO, ACGL)
[✓] Information Technology : 7 activos (ACN, ADBE, AMD, AKAM, APH, ADI, AAPL)
[✓] Health Care          : 6 activos (ABT, ABBV, A, ALGN, AMGN, BAX)
[✓] Consumer Discretionary : 5 activos (AMZN, APTV, AZO, BBY, BKNG)
[✓] Consumer Staples     : 4 activos (MO, ADM, BF-B, BG)
[✓] Utilities            : 3 activos (AES, LNT, AEE)
[✓] Real Estate           : 3 activos (ARE, AMT, AVB)
[✓] Materials            : 3 activos (APD, ALB, AMCR)
[✓] Communication Services : 2 activos (GOOGL, T)
[✓] Energy                : 2 activos (APA, BKR)

=====
[✓] FASE 1 COMPLETADA: 50 ACTIVOS CARGADOS Y VALIDADOS
=====
LISTADO FINAL DE TICKERS (MUESTRA ESTRATIFICADA):
MMM, AOS, ALLE, AME, ADP, AXON, BA, AFL, ALL, AXP, AIG, AMP, AON, APO, ACGL
ACN, ADBE, AMD, AKAM, APH, ADI, AAPL, ABT, ABBV, A, ALGN, AMGN, BAX, AMZN, APTV
AZO, BBY, BKNG, MO, ADM, BF-B, BG, AES, LNT, AEE, ARE, AMT, AVB, APD, ALB
AMCR, GOOGL, T, APA, BKR

=====
[📁] Archivo 'universo_tfm.csv' creado con 50 filas.
=====
```

Figura 10. Composición final del universo de inversión estratificado.

Para garantizar la integridad numérica, el algoritmo incorpora un bucle de ajuste de redondeo que asegura que la suma de los estratos sea exactamente de 50 activos, respetando la jerarquía de pesos del índice original.




Figura 11. Distribución de la muestra por sector.

Como se ilustra en la **Figura 11**, la distribución final de la muestra mantiene la jerarquía de pesos del índice original, donde sectores como el financiero e industrial presentan una mayor densidad de activos frente a sectores más concentrados como el de servicios de comunicación o energía.

Protocolo de Supervivencia y Calidad del Datos

Una vez definida la cuota por sector, la elección de las empresas específicas no responde a una selección discrecional, sino a un **protocolo de filtrado secuencial automatizado** diseñado para mitigar el sesgo de supervivencia y la redundancia:

- **Prelación por disponibilidad:** El algoritmo procesa los activos siguiendo el orden del listado oficial del índice. Esto elimina el *cherry-picking*, asegurando que no se elijan deliberadamente activos con rendimientos pasados sobresalientes.
- **Filtro de profundidad histórica (Sesgo de Supervivencia):** Se verifica que cada activo tenga series temporales [1] completas desde el **2 de enero de 2015**. Cualquier empresa sin un historial de 10 años es descartada, garantizando que el modelo aprenda de ciclos económicos completos.
- **Filtro de anti-redundancia estadística:** Se omiten activos que representen la misma entidad económica bajo distintas clases de acciones (ej. Alphabet o Fox Corp). Esto evita la **multicolinealidad**, impidiendo que señales duplicadas sesguen el entrenamiento.

Dimensionamiento del Dataset Final

Este proceso de filtrado técnico garantiza un dataset robusto y auditable. Con una profundidad histórica de 10 años y aproximadamente 2.760 sesiones por activo, el volumen total de datos procesados asciende a 138.000 registros aproximadamente (50x 2760).

La composición definitiva de la muestra, que servirá de base para la "Tabla Maestra", se detalla en la siguiente tabla:

Sector GICS	Activos Seleccionados	Peso Muestra (%)
Financials	8	16%
Industrials	7	14%
Information Technology	7	14%
Health Care	6	12%
Consumer Discretionary	5	10%
Consumer Staples	4	8%
Utilities	3	6%
Real Estate	3	6%
Materials	3	6%
Communication Services	2	4%
Energy	2	4%
Total General	50	100%

Figura 12. Número de acciones y porcentaje por sector.

3.2. Consolidación de la Tabla Maestra y Armonización de Fuentes

Tras la validación del universo de inversión, se procedió a la construcción del dataset final mediante un proceso de extracción y alineación de datos multifuente. A diferencia de un análisis de series temporales [1] convencional basado en ruido diario, este trabajo implementa un **enfoque de muestreo mensual (Month-End)**. Esta decisión metodológica permite capturar señales de tendencia más estables y reduce la volatilidad estocástica propia de las cotizaciones intradiarias.

Integración de Flujos de Datos (Multifuentes)

Para dotar al modelo XGBoost de una visión holística del mercado, se han armonizado tres flujos de información diferenciados:

Datos de Mercado (Precios): Cotizaciones de cierre ajustadas de los 50 activos y del índice S&P 500 (^GSPC). Estos datos son la base para el cálculo de indicadores de momento y rentabilidades relativas.

Indicadores de Sentimiento y Riesgo: Se incorpora el **Índice VIX [19]**, (*CBOE Volatility Index*) como *proxy* del sentimiento de mercado. Esto permite al modelo identificar "regímenes de miedo" o complacencia, ajustando sus predicciones según el entorno de riesgo sistémico.

Variables Macroeconómicas y Curva de Tipos: Se han integrado los *Treasury Yields* de 10 años (^TNX) y las letras a 3 meses (^IRX). La combinación de ambos permite al modelo interpretar la **pendiente de la curva de tipos**, un predictor histórico de recesiones. Asimismo, se ha integrado una serie de **inflación anualizada** para contextualizar el rendimiento de los activos en entornos de pérdida de poder adquisitivo.

Transformación de Frecuencia y Reducción de Ruido

Aunque el historial inicial abarca aproximadamente 138.000 registros diarios, el algoritmo de ingeniería de características consolida la información en una frecuencia mensual. El dataset final resultante consta de aproximadamente **6.700 vectores de entrenamiento** (50 activos x 134 meses).

Esta reducción controlada se justifica bajo tres premisas de rigor financiero:

- **Mitigación de la autocorrelación:** Evita que el modelo aprenda patrones repetitivos de días consecutivos que no aportan valor predictivo a largo plazo.
- **Alineación Macroeconómica:** Dado que indicadores como la inflación o los tipos de interés tienen un impacto estructural mensual, una frecuencia mayor carecería de sentido explicativo.
- **Viabilidad Estratégica:** El modelo se orienta a una gestión de activos de medio plazo con rebalanceo mensual, alineándose con los estándares operativos de la industria de inversión.

Estructura de la Tabla Maestra (Feature Set)

El artefacto de datos consolidado (tabla_maestra_tfm.csv) constituye el núcleo de conocimiento del modelo, integrando la información de mercado y el entorno económico en un registro mensual único. Las variables que componen el dataset final se definen a continuación:

- **Date:** Marcador temporal que identifica el cierre de cada mes bajo el estándar *Monthly-End*.
- **ticker:** Identificador alfanumérico único para cada uno de los activos del universo de inversión.
- **rsi:** Índice de fuerza relativa que detecta niveles de saturación del precio (sobrecompra o sobreventa). Se calcula usando la biblioteca *panda_ta* [13] sobre los precios de cierre.
- **macd_hist:** Histograma que mide la aceleración o pérdida de impulso en la tendencia del activo. Se calcula mediante el algoritmo MACD (diferencia entre EMAs).
- **ret_1m:** Rentabilidad porcentual del mes previo calculada a partir de los precios de cierre ajustados. Se calcula como el cambio porcentual (*pct_change*) de los últimos 21 días de cotización.
- **dist_sma_200:** Separación porcentual entre el precio de cierre y su media móvil simple de 200 días para identificar la tendencia estructural.
- **vix:** Índice de volatilidad implícita que actúa como *proxy* del nivel de riesgo y miedo en el mercado.
- **inflacion_anual:** Tasa de variación de precios que contextualiza el rendimiento de los activos según el régimen inflacionario. Esta variable se genera mediante un modelado por tramos anuales al que se le añade ruido aleatorio (*distribución normal*) para aumentar la robustez del aprendizaje.
- **curva_tipos:** Diferencial de tipos de interés (10Y - 3M) utilizado como indicador predictivo del ciclo económico. Se calcula restando el rendimiento de las letras a 3 meses ($\wedge$ IRX) al rendimiento del bono a 10 años ($\wedge$ TNX).
- **bono_10y:** Rendimiento nominal del Tesoro a 10 años que representa el coste del capital y la tasa libre de riesgo.

- **target:** Etiqueta predictiva que clasifica el exceso de retorno futuro frente al S&P 500 en tres categorías: **Clase 2** (Compra: supera al índice >1%), **Clase 1** (Neutral: $\pm 1\%$ respecto al índice) y **Clase 0** (Venta: rinde <1% por debajo del índice). Se calcula mediante la comparación de los retornos futuros del activo frente a los del S&P 500, aplicada tras el rebalanceo mensual.

Resultado del Conjunto de Datos y Balance de Clases

Tras la consolidación de la Tabla Maestra, se analizan los resultados sobre los **6.700 vectores de datos** resultantes para verificar la coherencia económica de la muestra y la distribución de las etiquetas de aprendizaje. Los hallazgos principales se detallan a continuación y se obtienen de la **Figura13**:

- **Validación de Variables Macroeconómicas:** El dataset refleja una **inflación media del 3,04%** y una **curva de tipos media de 0,70 puntos**. Estos valores son consistentes con el marco macroeconómico del periodo 2015-2025. La inclusión de ruido estocástico en la inflación ha permitido generar un entorno de entrenamiento más rico, evitando que el modelo se ajuste de forma simplista a valores fijos y obligándolo a aprender la relación entre el crecimiento de precios y el rendimiento bursátil.
- **Análisis del Balance de Clases:** La distribución de la variable *target* es un factor crítico para evitar sesgos en el modelo XGBoost. La auditoría muestra una distribución equilibrada entre los extremos:
 - **Clase 2 (Compra): 43,70%** de las muestras.
 - **Clase 0 (Venta): 42,54%** de las muestras.
 - **Clase 1 (Neutral): 13,76%** de las muestras

Esta segmentación indica que el mercado presenta una alta dispersión mensual, donde la gran mayoría de los activos tienden a desviarse más de un 1% respecto al índice. Para el modelo, contar con un volumen casi simétrico de ejemplos de éxito (Clase 2) y fracaso relativo (Clase 0) es el escenario óptimo, ya que facilita la identificación de los factores técnicos y macroeconómicos que separan a los ganadores de los perdedores del mercado.

🚀 Fase 1: Descargando Precios y Activos de Referencia (Yahoo)...
🌸 Fase 2: Procesando 50 activos con frecuencia mensual...

AUDITORÍA DE DATOS

📁 Archivo generado: tabla_maestra_tfm.csv
📊 Total de muestras: 6700
📈 Inflación media: 3.04%
📉 Curva Tipos media: 0.70 pts

⊠ Clase 0 [VENTA (Bajista)]: 42.54%
⊠ Clase 1 [NEUTRAL (Estable)]: 13.76%
⊠ Clase 2 [COMPRA (Alcista)]: 43.70%

✅ Proceso finalizado. El dataset está listo para entrenar.

Figura 13. Resumen análisis datos entrenamiento

3.3. Arquitectura y Lógica del Algoritmo XGBoost

Una vez consolidada la base de datos con **6.700 muestras**, se procedió a la fase de modelización algorítmica. En este apartado, se exponen los resultados derivados del entrenamiento del modelo **XGBoost**, analizando su capacidad para transformar variables macroeconómicas y técnicas en señales de inversión accionables. A continuación, se detalla el rendimiento estadístico del sistema mediante métricas de precisión y matrices de confusión, así como la jerarquía interna de toma de decisiones del algoritmo. Este análisis permite validar cómo el software ha capturado las dinámicas del mercado estadounidense durante el periodo de validación (**2023-2025**) y cómo estos resultados sientan las bases para la simulación monetaria de carteras.

Configuración de Hiperparámetros y Estrategia de Aprendizaje

El modelo desarrollado se basa en el algoritmo **Extreme Gradient Boosting (XGBoost)** [14], una implementación avanzada de árboles de decisión con aumento de gradiente [14]. A diferencia de un bosque aleatorio convencional, XGBoost construye los árboles de forma secuencial, donde cada nuevo árbol intenta corregir los errores de los anteriores mediante la optimización de una función de pérdida diferenciable.

Para este proyecto, el software se ha configurado con una arquitectura orientada a la robustez, utilizando los siguientes hiperparámetros estratégicos que se muestran en la **Figura 14**:

- **n_estimators (300)** [14]: Determina el número total de árboles de decisión que se construirán secuencialmente. Se ha optado por un valor de 300 para

permitir que el modelo tenga suficientes iteraciones para corregir errores residuales. Al combinarse con un *Learning Rate* bajo, este número de estimadores garantiza que el algoritmo alcance un estado de aprendizaje óptimo sin riesgo de explosión del error.

- **Max Depth (3) [14]:** A diferencia de modelos más profundos, se ha limitado la profundidad a 3 niveles. Esta restricción es fundamental para evitar el *overfitting*, forzando al algoritmo a capturar solo las interacciones más significativas (como la relación entre el **VIX** y el **RSI**) sin procesar el ruido intrínseco de los precios diarios.
- **Learning Rate (0,01) [14]:** Se ha seleccionado una tasa de aprendizaje reducida (estilo "*slow learner*") para garantizar una convergencia estable. Esto permite que el modelo aprenda patrones de largo plazo de forma incremental, minimizando el riesgo de memorización de anomalías temporales.
- **Gamma (1) [14]:** Este parámetro actúa como un umbral de regularización. Especifica la reducción mínima de la pérdida requerida para realizar una partición adicional en un nodo del árbol. Al fijar gamma=1, estamos introduciendo un nivel de "conservadurismo" en el modelo: el algoritmo solo creará ramas nuevas si la ganancia de información es significativa, lo que actúa como un filtro natural contra patrones ruidos de corto plazo que no tienen relevancia estadística real.
- **Subsample (0,8) [14]:** Indica que, antes de construir cada árbol, el modelo utiliza una muestra aleatoria correspondiente al 80% del dataset de entrenamiento. Esta técnica de *stochastic gradient boosting* introduce una ligera variabilidad que ayuda a que el modelo sea más robusto ante valores atípicos (*outliers*) y evita que se vuelva excesivamente dependiente de un grupo específico de datos históricos.
- **Colsample_bytree (0,8) [14]:** De manera similar al submuestreo de filas, este parámetro limita el número de variables (features) disponibles para cada árbol al 80%. Al no permitir que cada árbol vea todas las variables (como el VIX, RSI o la Inflación) al mismo tiempo, obligamos al sistema a encontrar patrones ocultos en diferentes combinaciones de datos. Esto previene que una sola variable dominante opaque el poder predictivo del resto del conjunto de datos.
- **Objective (multi:softprob) [14]:** Esta función objetivo es el núcleo del sistema. En lugar de una clasificación binaria rígida, el software calcula la probabilidad estadística para tres categorías (**Venta, Neutral, Compra**). Esta arquitectura permite que el simulador posterior seleccione solo activos

con un nivel de confianza superior al **45%**, actuando como un filtro de calidad para la selección del "Top 5".

- **Random State (42) [14]:** Se ha fijado una semilla de aleatoriedad (seed) para garantizar la **reproducibilidad de los resultados**. En algoritmos basados en procesos estocásticos como XGBoost (que utiliza submuestreo de datos y variables), el uso de una semilla fija asegura que el modelo produzca exactamente los mismos resultados en cada ejecución. El valor 42, ampliamente adoptado en la comunidad científica, permite que el experimento sea auditable y verificable por otros investigadores, eliminando la variabilidad derivada del azar en la construcción de los árboles de decisión.

```
# =====
# 4. CONFIGURACIÓN DEL MODELO XGBOOST
# =====
model = xgb.XGBClassifier(
    n_estimators=300,
    max_depth=3,
    learning_rate=0.01,
    gamma=1,
    subsample=0.8,
    colsample_bytree=0.8,
    objective='multi:softprob',
    random_state=42
)

model.fit(X_train, y_train)
```

Figura 14. Hiperparámetros del modelo.

Análisis Detallado de la Precisión (Accuracy) y Errores

El rendimiento del modelo se evaluó mediante un método de *hold-out* cronológico, utilizando el periodo **2023-2025** como conjunto de prueba. Esta metodología es crítica para garantizar la ausencia de filtración de datos (*look-ahead bias*), asegurando que el algoritmo solo tome decisiones con la información que estaría disponible en tiempo real.

El **Accuracy obtenido del 44.12%** debe interpretarse bajo el prisma de la Hipótesis de los Mercados Eficientes (HME). Mientras que en problemas de clasificación general se buscan precisiones muy elevadas, en finanzas cuantitativas la naturaleza estocástica del precio impone un techo de predictibilidad bajo. En un escenario de

clasificación ternaria, donde la esperanza matemática de acierto por puro azar es del **33.33%**, el incremento del **10.79%** obtenido por el modelo representa una ventaja competitiva (*edge*) estadísticamente significativa.

Al observar los resultados detallados en el **Reporte de Clasificación**, se extraen las siguientes conclusiones técnicas:

- **Detección de Oportunidades (Clase 2 - Compra):** El sistema alcanza un **Recall del 53%**. Este es un resultado de gran valor para la estrategia, ya que indica que el modelo es capaz de identificar más de la mitad de los activos que realmente batirán al mercado por más de un 1%. Aunque la precisión en esta clase se sitúa en el **39%**, la metodología de selección posterior del "Top 5" (basada en probabilidades) permite filtrar estos aciertos para concentrar la cartera en las señales más robustas.
- **Identificación de Riesgos (Clase 0 - Venta):** El modelo presenta una **Precisión del 49%** y un **Recall del 48%** en la identificación de activos bajistas. Esta capacidad es fundamental para la preservación de capital, permitiendo al sistema descartar de forma efectiva casi la mitad de los activos que infra-rendirán respecto al índice S&P 500.
- **Comportamiento en la Clase Neutral (Clase 1):** El reporte muestra valores de 0.00 en precisión y recall para esta clase. Este fenómeno indica una **polarización del modelo hacia los extremos**. En un entorno de mercado volátil como el periodo 2023-2025, el algoritmo XGBoost optimiza la función de pérdida asignando las muestras a las clases con mayor "momento" esperado (Compra o Venta). Para una estrategia de gestión activa orientada a la búsqueda de *Alpha*, esta característica es preferible a un modelo excesivamente conservador que no sea capaz de emitir señales operativas.

En conclusión, los resultados establecen una base sólida con esperanza matemática positiva. La rentabilidad final del sistema no depende del acierto total, sino de la explotación estadística de este diferencial sobre la aleatoriedad, transformando la precisión del **44.12%** en una herramienta eficaz para la selección de activos ganadores.

```

--- CONTROL 1: Dimensiones del Dataset ---
Total de muestras: 6700
--- CONTROL 2: División Temporal ---
Entrenamiento: hasta 2022 | Test: 2023-2025

--- CONTROL 3: Rendimiento del Modelo ---
Accuracy en Test: 44.12%

Reporte de Clasificación:
      precision    recall  f1-score   support

     0.0         0.49      0.48      0.49        834
     1.0         0.00      0.00      0.00         214
     2.0         0.39      0.53      0.45        652

 accuracy          0.30      0.34      0.31       1700
  macro avg          0.30      0.34      0.31       1700
 weighted avg          0.39      0.44      0.41       1700

```




Figura 15. Matriz de Confusión – Validación (2023-2025).

Como se observa en la diagonal principal de la **Figura 15 (Matriz de Confusión) [18]**, el modelo demuestra una capacidad discriminativa clara en los extremos del espectro de retorno, centrando su potencia predictiva en las señales de alta convicción.

- **Detección de "Perdedores" (Clase 0):** El algoritmo muestra una notable solvencia en la identificación de activos con bajo rendimiento relativo. Logra clasificar correctamente **404 muestras** en esta categoría, alcanzando una precisión del **49%** y un *recall* del **48%**. En gestión de carteras, esta capacidad es tan determinante como el acierto en las compras; permite al sistema descartar activos que lastrarían el rendimiento global, evitando el "arrastre" negativo en la cartera final.

- **Identificación de Oportunidades Alpha (Clase 2):** En el extremo opuesto, el modelo identifica correctamente **346 casos** de éxito relativo (activos que batan al índice). El elevado *recall* en esta clase (**53%**) asegura que el sistema captura la mayoría de las tendencias alcistas disponibles en el universo de inversión, sentando las bases para la generación de rentabilidad excedente.
- **Polarización Predictiva (Clase 1):** El hecho de que la Clase 1 (Neutral) presente una tasa de acierto nula se justifica por una decisión de diseño orientada a la **polarización predictiva**. En horizontes mensuales, los activos del S&P 500 suelen reaccionar con fuerza a datos macroeconómicos y eventos corporativos, alejándose de comportamientos laterales. El modelo XGBoost, al estar configurado para la toma de decisiones activa, prioriza la identificación de tendencias direccionales claras (Compra o Venta), ignorando las zonas de ruido estadístico donde no existe una ventaja competitiva clara

Esta discriminación efectiva permite concentrar el capital únicamente en aquellos activos que se sitúan en el extremo superior de la distribución de probabilidad. La capacidad de filtrar el ruido y centrarse en los extremos es lo que constituye la base del **Alpha** generado en la simulación monetaria posterior, validando la utilidad del algoritmo como una herramienta de selección de activos (*stock picking*) superior al azar.

Interpretación Socioeconómica de las Variables (Feature Importance)

Uno de los mayores aportes de este estudio es la transparencia del modelo, rompiendo con el paradigma de "caja negra" que suele rodear a los sistemas de inteligencia artificial. Para ello, se ha empleado el análisis de la métrica de **Ganancia (Gain Score [9])**, la cual cuantifica la contribución relativa de cada variable a la reducción de la incertidumbre en cada nodo de decisión del ensamble XGBoost.




Figura 16. Importancia de las Variables Macro.

A diferencia de los enfoques puramente técnicos, la jerarquía de variables revelada por el algoritmo (ver **Figura 16**) valida la tesis central de este trabajo: la existencia de un equilibrio simbiótico entre los fundamentos macroeconómicos y el análisis técnico de precio

1. **Dominancia del Entorno Monetario (bono_10y):** El rendimiento del Bono a 10 años lidera la jerarquía con un *Gain Score* de **3,07**. El algoritmo identifica correctamente que este activo actúa como la tasa libre de riesgo global. En el periodo de validación (2023-2025), marcado por una inflación persistente, el modelo "entiende" que el bono es el principal catalizador de las valoraciones; cualquier repunte en su rentabilidad incrementa la tasa de descuento de los flujos futuros, penalizando especialmente a los activos de renta variable.
2. **Confirmación de Tendencia y Momentum (macd_hist y dist_sma_200):** El histograma del MACD (**3,04**) y la distancia a la media de 200 días (**2,92**) se posicionan como los pilares técnicos. El modelo utiliza el MACD para detectar la aceleración del precio, mientras que la *dist_sma_200* actúa como un termómetro de la salud estructural de la tendencia. Esta combinación permite al algoritmo distinguir entre rebotes efímeros y cambios de tendencia sostenibles.

3. **Reguladores de Sentimiento y Riesgo (vix e inflacion_anual):** El índice VIX (**2,91**) funciona como un regulador dinámico de volatilidad en el árbol de decisión, ajustando la confianza de las predicciones según el nivel de pánico de los inversores. Por su parte, la **inflación anual (2,66)** aporta el contexto cíclico, permitiendo al modelo correlacionar el poder adquisitivo con la probabilidad de endurecimiento monetario por parte de la Reserva Federal.
4. **Osciladores y Ciclo Económico (rsi y curva_tipos):** El RSI (**2,75**) y el retorno mensual ret_1m (**2,78**) afinan el *timing* detectando condiciones de agotamiento. Finalmente, la Curva de Tipos (**2,59**) cierra el ranking; aunque es la variable con menor peso relativo, mantiene un aporte equilibrado, funcionando como un "semáforo" de riesgo sistémico que alerta sobre posibles recesiones inminentes.

Salida del Software y Preparación del Backtesting

El ciclo de ejecución del software concluye transformando las inferencias abstractas del algoritmo en un dataset estructurado y accionable denominado `predicciones_modelo.csv`. Este archivo constituye un entregable de ingeniería financiera que normaliza las predicciones para su consumo inmediato por motores de simulación o algoritmos de ejecución.

Date	ticker	target	prediccion	prob_compra
2023-01-31	A	0	0	0.37191036
2023-01-31	AAPL	2	2	0.51507634
2023-01-31	ABBV	2	0	0.38859555
2023-01-31	ABT	0	0	0.400125
2023-01-31	ACGL	2	2	0.45499673
2023-01-31	ACN	0	0	0.38755053
2023-01-31	ADBE	0	2	0.46258402
2023-01-31	ADI	2	0	0.38508153
2023-01-31	ADM	1	0	0.405636
2023-01-31	ADP	1	0	0.40426835

Figura 17. Muestra datos `predicciones_modelo.csv`.

Para garantizar la trazabilidad y la correcta interpretación de los resultados en la fase de *backtesting*, cada registro del archivo (visualizado en la **Figura 17**) se desglosa en las siguientes columnas fundamentales:

- **Date (Timestamp):** Indica el momento exacto del cierre de la vela mensual. Es el ancla temporal que permite al motor de backtesting sincronizar la predicción [8] generada en el tiempo T con los retornos reales observados en el tiempo T+1, eliminando cualquier sesgo de anticipación (*look-ahead bias*).
- **Ticker:** Identificador unívoco del instrumento financiero. Facilita la gestión multi-activo y la comparación de señales entre los diferentes componentes del universo de inversión.
- **Target:** El retorno real que el activo experimentó en el periodo siguiente. Esta columna es vital para el control de calidad, permitiendo auditar la precisión de la predicción [8] frente a la realidad del mercado.
- **Prediccion (Pred_Clase):** Resultado categórico del modelo (0: Venta, 1: Neutral, 2: Compra). Es la señal simplificada que dicta la dirección operativa basada en la clase con mayor probabilidad.
- **PROB_COMPRA:** Constituye la métrica crítica del sistema. Representa la confianza logística (valor entre 0 y 1) que el algoritmo XGBoost asigna a la probabilidad de que el activo pertenezca a la clase alcista (Clase 2).

La disponibilidad de la variable **prob_compra** permite establecer umbrales de activación (*thresholds*) dinámicos. En el diseño de esta estrategia, se ha empleado un **umbral de 0,45**, lo que garantiza que solo se ejecuten órdenes en activos donde el modelo posee una certeza significativamente superior a la probabilidad aleatoria (33%). Como se demuestra en los resultados posteriores, ordenar los activos por este nivel de convicción permite capturar un **Alpha superior**, seleccionando únicamente los activos con mayor esperanza matemática.

Este entregable convierte un algoritmo de aprendizaje supervisado en una **Herramienta de Soporte a la Decisión (DSS)**. Como se observa en la muestra de datos, cada registro constituye una unidad de información autónoma que permite al motor de simulación no solo determinar qué activos adquirir, sino priorizar la ponderación de cada posición en función de la certidumbre estadística del modelo. Este archivo representa, en última instancia, el puente definitivo entre la inteligencia predictiva y la ejecución financiera.

3.4. Motor de Simulación Monetaria y Gestión de Cartera

Una vez generadas las señales predictivas, el sistema se somete a una prueba de estrés financiero mediante un simulador de carteras desarrollado *ad hoc*. Este motor no solo valida la dirección del precio, sino la viabilidad económica del modelo considerando capital real y fricciones de mercado.

Lógica Algorítmica del Simulador

La validación económica del modelo se articula a través de la función **simulate_monetary**, cuya arquitectura técnica ha sido diseñada para replicar un entorno de ejecución real mediante la reinversión compuesta del capital y la gestión de costes operativos. Esta función destaca por la integración de tres pilares de control financiero:

- **Modelado de Fricción de Mercado:** Se ha definido una tasa del **0,25% de comisión mensual** (`comision_operacion = 0.0025`). Este parámetro es fundamental para la integridad del estudio, ya que cubre de forma realista los cánones de bolsa, los *fees* de intermediación y el *slippage* (deslizamiento de precios) esperado en activos de alta liquidez del S&P 500 dentro de los estándares de los brókeres actuales.
- **Filtro de Convicción Estadística (Gatekeeper):** El simulador implementa un umbral de activación basado en la probabilidad logística, donde **prob_compra > 0,45**. Este mecanismo actúa como un gestor de riesgos automático: si el modelo XGBoost no identifica activos que superen este nivel de confianza, el capital permanece en liquidez (**CASH**). Esta estrategia protege la integridad de la cartera en periodos de incertidumbre técnica o lateralidad del mercado.
- **Dinámica de Reinversión y Capitalización:** El algoritmo actualiza el capital disponible al cierre de cada periodo mensual, aplicando los rendimientos netos sobre el nuevo balance. Esta metodología permite evaluar el efecto del **interés compuesto** y la capacidad de la IA para gestionar carteras con un patrimonio creciente, simulando la evolución de una cuenta de inversión real a largo plazo.

Composición de Carteras y Selección de Activos

El motor de selección de la IA demuestra una clara preferencia por activos con fuerte *momentum* y resiliencia macroeconómica. La capacidad del modelo para rotar mensualmente la totalidad de la exposición permite que la cartera se adapte con agilidad a las condiciones cambiantes del mercado, un factor diferencial respecto a las estrategias de comprar y mantener (*Buy & Hold*).

A continuación, se detalla la rotación de activos observada en el último semestre del estudio (**Figura 18**), la cual sirve como caso de éxito para entender la lógica del algoritmo:

```
=====
ACCIONES ELEGIDAS POR LA IA (ÚLTIMO SEMESTRE)
=====
MES: 2025-05
> TOP 5 ($5k):  ADBE, AMP, AMD, ADI, AAPL
> TOP 10 ($10k): ADBE, AMP, AMD, ADI, AAPL, AXP, ACN, ALB, APO, AMZN
-----
MES: 2025-06
> TOP 5 ($5k):  AXON, APH, BA, AMGN, APTV
> TOP 10 ($10k): AXON, APH, BA, AMGN, APTV, ARE, AON, AXP, AMD, GOOGL
-----
MES: 2025-07
> TOP 5 ($5k):  AXON, APH, ALGN, AMP, APO
> TOP 10 ($10k): AXON, APH, ALGN, AMP, APO, AVB, AXP, AAPL, MMM, AMD
-----
MES: 2025-08
> TOP 5 ($5k):  BAX, AES, AZO, ALGN, ADP
> TOP 10 ($10k): BAX, AES, AZO, ALGN, ADP, APH, ALLE, BA, BG, BKR
-----
MES: 2025-09
> TOP 5 ($5k):  ACN, ALB, ALGN, ADBE, APA
> TOP 10 ($10k): ACN, ALB, ALGN, ADBE, APA, ADM, AMP, APH, AMD, APTV
-----
MES: 2025-10
> TOP 5 ($5k):  APH, GOOGL, ACN, APTV, ALLE
> TOP 10 ($10k): APH, GOOGL, ACN, APTV, ALLE, AMP, AMD, ALL, MMM, APO
```

Figura 18. Acciones elegidas modelo IA top 5 y top 10.

El motor de decisión no actúa de forma estática; ajusta la exposición basándose en la **probabilidad logística de éxito**. La comparativa entre las carteras Top 5 y Top 10 revela cómo el modelo escala su confianza según el número de señales detectadas:

- **Concentración en el Top 5 (Alta Convicción):** En periodos de expansión, como mayo de 2025, el modelo filtró únicamente activos con una estructura técnica y macroeconómica buena como **ADBE, AMP y AMD**. Esta selección actúa como un "estilete", buscando capturar movimientos rápidos en acciones de alto crecimiento (*growth*).
- **Diversificación en el Top 10[15] (Beta Inteligente):** Al ampliar el espectro a 10 activos, el modelo incluye acciones como **AXP, APO y AMZN**. Esta estrategia permite que la cartera capture el crecimiento sectorial en su conjunto, manteniendo una correlación más sana con el mercado alcista y reduciendo el impacto de la volatilidad individual (riesgo idiosincrásico).

El modelo demostró una capacidad de anticipación notable ante cambios en la volatilidad (**VIX**) y los tipos de interés (**bono_10y**), variables que, como se analizó anteriormente, lideran la jerarquía del modelo con un *Gain Score* de **2,87** y **3,09** respectivamente. Esta sensibilidad permitió realizar las siguientes maniobras:

- **Rotación Defensiva (agosto 2025):** Mientras el mercado mostraba signos de agotamiento, el modelo rotó agresivamente hacia sectores defensivos. La cartera Top 5 se concentró en valores como **BAX (Baxter International), AZO (AutoZone) y ADP**, que históricamente presentan una baja correlación con el pánico sistémico. En el Top 10, la inclusión de **BKR (Baker Hughes) y APH** construyó un "escudo diversificado" que mitigó el impacto de la volatilidad detectada por el algoritmo.
- **Convergencia y Crecimiento (octubre 2025):** Al finalizar el periodo de estudio, ambas carteras convergieron en nombres con fuerte respaldo institucional y *momentum* como **GOOGL, ACN y APH**. Esta alineación permitió capturar el rebote final del mercado, beneficiándose de la estabilización en los rendimientos de la deuda soberana.

Esta gestión dinámica no solo superó al índice en términos de rentabilidad, sino también en calidad de ejecución:

- **Cartera IA Top 5:** Alcanzó un valor final de **\$7.721,18**, lo que supone un **ROI del 54,42%** y un **Alpha de \$225,82** sobre su referencia pasiva.
- **Cartera IA Top 10:** Logró el rendimiento más destacado con un valor final de **\$17.004,22**, representando un **ROI del 70,04%** y un **Alpha de \$2.013,50**.

Este diferencial confirma que la combinación de un umbral de probabilidad del **0.45** con una selección de 10 activos maximiza la esperanza matemática del sistema, permitiendo que la diversificación [15] capture más ineficiencias del mercado que la concentración extrema.

Correlación con el Escenario Macroeconómico y Volatilidad

Para validar la robustez y la capacidad adaptativa del algoritmo, es imperativo analizar su rendimiento en el contexto de las variables externas críticas que definen el régimen de mercado. El modelo no opera en el vacío; su éxito depende de la interpretación de la volatilidad (**VIX**), la presión inflacionaria y el rendimiento del **Bono a 10 años (GS10)**, tal como se detalla en la **Figura 19**.




Figura 19. Rentabilidad acumulada vs Escenario económico y volatilidad.

Del análisis exhaustivo de esta comparativa se extraen las siguientes conclusiones clave que justifican la generación de Alpha:

- A. **Resiliencia ante picos de volatilidad (VIX):** La variable **VIX** posee un peso determinante en la arquitectura del modelo (**Gain Score: 2,91**). Al observar las áreas sombreadas en gris (periodos de repunte del VIX), se evidencia que mientras el S&P 500 sufre correcciones abruptas, las carteras dirigidas por la IA tienden a lateralizar o corregir con una pendiente mucho más suave. **El efecto "Amortiguador":** El filtro de probabilidad de compra del **0,45** actúa como un mecanismo de defensa. Ante un incremento del riesgo sistémico, el modelo eleva sus exigencias estadísticas, lo que resulta en una reducción de la exposición o una rotación hacia activos con betas más bajas, preservando el capital durante el pánico del mercado.

- B. **Generación de Valor Real: Superación de la Inflación y Renta Fija:** Uno de los hitos más relevantes del estudio es la capacidad del modelo para batir a los activos de refugio y al coste de la vida:
 - **Frente a la Inflación (Gain Score: 2,66):** La rentabilidad acumulada de ambas carteras se sitúa sistemáticamente por encima de la línea de inflación. Esto confirma que el algoritmo es una herramienta eficaz para la **preservación y crecimiento del poder adquisitivo** en términos reales.

 - **Frente al Bono 10Y (Gain Score: 3,07):** A pesar de que los tipos de interés alcanzaron niveles restrictivos durante el periodo analizado, el modelo fue capaz de identificar activos cuyo rendimiento superaba con creces la rentabilidad libre de riesgo. Esto demuestra que la IA puede navegar entornos de política monetaria contractiva seleccionando empresas con fundamentales capaces de absorber el endurecimiento del crédito.

- C. **Análisis de la Divergencia de Alpha:** A partir de mediados de 2024, se observa un fenómeno de **desacoplamiento alcista**. Mientras que el S&P 500 (línea roja discontinua) mantiene un crecimiento sólido pero lineal del 49,9%, la **IA Top 10** (línea azul) inicia una trayectoria exponencial hasta alcanzar el **70,0% de ROI**. Esta divergencia no es solo cuantitativa, sino cualitativa: el modelo no se limita a seguir la tendencia general (*Beta*), sino que realiza una **selección de Alpha puro**, concentrando el capital en los líderes sectoriales que impulsaron el rally tecnológico y energético del periodo.

D. Paradoja de la Diversificación [15]: Eficiencia del Top 10 vs. Top 5: A diferencia de la teoría convencional que asocia mayor concentración con mayor retorno, en esta simulación la cartera **IA Top 10 (70,0%)** superó a la **IA Top 5 (54,4%)**. Este fenómeno se explica por la estructura de riesgo:

- **Robustez Estadística:** En una cartera de solo 5 activos, el impacto adverso de un solo valor (riesgo idiosincrásico) penaliza severamente la curva de equidad.
- **Optimización de la Señal:** La cartera Top 10 permite capturar un espectro más amplio de señales de alta probabilidad. Al estar más diversificada, reduce la volatilidad de la cartera y permite una **capitalización compuesta más eficiente**, ya que las rachas de pérdidas de activos individuales se compensan entre sí, manteniendo la curva de crecimiento en una trayectoria más estable y ascendente.

Análisis de Resultados: IA vs. Estrategia Pasiva (S&P 500)

Los resultados finales confirman la capacidad del algoritmo predictivo para identificar ineficiencias de mercado y convertirlas en oportunidades de inversión que superan sistemáticamente al índice de referencia. Para una comprensión exhaustiva, se presenta a continuación la comparativa de las métricas clave al cierre del periodo 2023-2025:

=====				
INFORME DE RENDIMIENTO ECONÓMICO FINAL: IA VS ESTRATEGIA PASIVA (2023-2025)				
=====				
MÉTRICA	IA TOP 5	S&P 500 (\$5k)	IA TOP 10	S&P 500 (\$10k)

Inversión Inicial	\$5,000.00	\$5,000.00	\$10,000.00	\$10,000.00
Valor Final	\$7,721.18	\$7,495.36	\$17,004.22	\$14,990.72
BENEFICIO NETO	\$2,721.18	\$2,495.36	\$7,004.22	\$4,990.72
ROI Total (%)	54.42	% 49.91	% 70.04	% 49.91

ALPHA (Extra IA)	\$225.82	-	\$2,013.50	-
=====				

Figura 20. Comparativa rendimiento cartera pasiva vs IA.

Como se detalla en la **Figura 20** y se visualiza en la **Figura 21**, ambas configuraciones de la IA logran el objetivo fundamental de cualquier gestión activa: **batir al mercado (S&P 500)** tras descontar comisiones operativas.




Figura 21. Evolución valor de la cartera vs SP500.

Del análisis cuantitativo de la evolución patrimonial se extraen las siguientes conclusiones fundamentales:

- A. Generación de Alpha y Desacoplamiento Alcista:** La cartera **IA Top 10** presenta un desempeño excepcional, culminando con un valor de **\$17.004,22**. Lo más relevante no es solo el saldo final, sino el fenómeno de desacoplamiento observado a partir de mediados de 2024. Mientras que la gestión pasiva mantiene una pendiente de crecimiento inercial, la IA acelera su rendimiento, logrando un **Alpha neto de \$2.013,50** sobre una base de \$10.000. Esto sugiere que el modelo XGBoost es capaz de sobreponderar activos con una fuerza relativa superior, optimizando la captura de valor en los tramos más rentables del ciclo alcista actual.
- B. Robustez de la Selección de Alta Convicción (Top 5):** La configuración **IA Top 5** finaliza con **\$7.721,18**, superando los **\$7.495,36** de su benchmark de referencia. A pesar de ser una estrategia con una diversificación [15] mínima (solo 5 activos), su capacidad para batir al índice confirma la potencia del filtrado probabilístico. Este rendimiento se apoya en una lectura precisa de las variables líderes: la aceleración en la rentabilidad coincide con la estabilización del **Bono a 10 años (Gain Score: 3,07)** y un entorno de volatilidad controlada, lo que demuestra que el modelo detecta las ventanas de oportunidad óptimas para la toma de riesgo.

- C. Eficiencia Predictiva y Sensibilidad Técnica:** Un factor diferencial es la sensibilidad del algoritmo a indicadores de momento como el **MACD Histograma (Gain Score: 3,04)**. Mientras el S&P 500 se ve afectado por el ruido y la lateralidad, las carteras de la IA muestran una curva de equidad más decidida, evitando el "lastre" de sectores estancados mediante la rotación mensual.
- D. Conclusión sobre la Diversificación [15] Inteligente:** La comparativa final otorga una ventaja técnica a la diversificación [15] inteligente (Top 10). Al ampliar el número de activos bajo señales de alta probabilidad ($\text{prob_compra} > 0,45$), el sistema reduce la exposición al riesgo individual de cada acción sin diluir el retorno. Esta estrategia consolida una ventaja competitiva constante frente a la gestión pasiva tradicional, demostrando que la diversificación [15], cuando es guiada por un modelo de *Machine Learning* [4], robusto, no es solo una medida de seguridad, sino una herramienta para **maximizar la esperanza matemática** del sistema en el largo plazo.

Dashboard de Performance Consolidado: Análisis de Atribución y Eficiencia del Modelo Predictivo XGBoost

Como cierre del análisis de resultados, la **Figura 22** presenta el Dashboard de Performance Consolidado. Este panel no es solo una síntesis visual, sino la validación holística del modelo, donde se cruzan rentabilidad, riesgo y entorno macroeconómico entre 2023 y 2025




Figura 22. Dashboard de resultados visión general.

El panel superior **Figura 23** del dashboard confirma la jerarquía de las estrategias. La **IA Top 10** se consolida como la configuración óptima, alcanzando un multiplicador de **1,70** (ROI del 70.0%). El área sombreada en el gráfico de rentabilidad permite visualizar el **Alpha generado**, es decir, el exceso de retorno que el modelo XGBoost logra extraer del mercado gracias a su capacidad para identificar activos con una fuerza relativa superior a la media.

Por su parte, la **IA Top 5** mantiene un multiplicador de **1,54**. Aunque nominalmente es menor, su curva de equidad demuestra que, incluso con una concentración máxima, el algoritmo es capaz de batir al S&P 500 de forma sistemática, filtrando el "lastre" de sectores estancado



Figura 23. Comparativa histórico valor de la inversión.

En la **Figura 24**, el gráfico de dispersión sitúa a ambas carteras en la **zona de dominancia estocástica** (cuadrante superior izquierdo).

- **Optimización del Ratio de Sharpe [9,16]:** Ambas estrategias se sitúan por encima del punto rojo (S&P 500), demostrando que el modelo no solo gana más dinero, sino que lo hace de forma eficiente, ofreciendo un retorno superior por cada unidad de volatilidad asumida. Dicho esto, la estrategia IA TOP 10 es la que tiene mayor rendimiento con menor volatilidad, siendo esta la estrategia óptima compara con la IA TOP 5 y el S&P 500
- **Gestión de la Volatilidad:** Se observa que la IA Top 5 tiene una volatilidad aproximada ($\sim 0,20$) que la IA Top 10 ($\sim 0,17$). Esto valida la tesis de que la diversificación [15] inteligente en el Top 10 reduce el riesgo individual sin diluir significativamente el Alpha.



Figura 24. Eficiencia: Riesgo Vs Retorno.

La robustez del sistema se confirma al contrastar los resultados con las **Figuras 25 y 26**:

- **Lectura del VIX (VIX):** El modelo utiliza los picos de volatilidad (hasta 25 puntos) para rotar hacia activos defensivos. El filtro de probabilidad (>0.45) actúa como un "amortiguador" que evita los *drawdowns* profundos que sufre la gestión pasiva en momentos de pánico.
- **Sensibilidad al Bono 10Y:** El éxito de la selección de activos (como **GOOGL, ACN o APH**) está directamente correlacionado con la capacidad de la IA para monitorizar los tipos de interés. Al ser la variable con mayor *Gain Score* (3,07), el modelo ajusta la cartera según el coste del capital, anticipándose a las rotaciones sectoriales.




Figura 25. Volatilidad (VIX).




Figura 26. Tipos de interés (Bono 10Y).

Finalmente, los diagramas de *Asset Allocation* (**Figuras 27 y 28**) detallan la metodología de **Equiponderación** (*Equal-Weight*), una decisión estratégica que fundamenta la estabilidad del sistema:

- **Inteligencia Colectiva del Modelo:** Esta decisión asegura que el éxito sea el resultado de la "inteligencia colectiva" del modelo XGBoost. Al repartir el capital de forma equitativa (10% por activo en el Top 10 o 20% en el Top 5), se elimina la dependencia del rendimiento de un solo título, permitiendo que la rentabilidad sea el producto de una tasa de acierto sistémica.
- **Protección Mediante Diversificación [15] Guiada:** Nombres como **MMM**, **APO** y **ALL** en la cartera Top 10 añaden una capa de protección diversificada. Esto explica por qué esta configuración terminó siendo la ganadora absoluta del estudio; la diversificación [15] guiada por IA demostró ser la solución óptima para navegar entornos de mercado complejos, donde la concentración extrema puede ser penalizada por eventos inesperados en un solo activo.
- **Mitigación del Riesgo Individual:** El proceso de equiponderar elimina el riesgo de concentración excesiva, asegurando que el sistema se beneficie de la "precisión de conjunto" del clasificador. La transición visual entre ambos gráficos de ponderación permite observar cómo, a pesar de compartir nombres núcleo como **GOOGL** y **APH**, el Top 10 añade una capa de protección mediante activos con diferentes dinámicas de mercado. Esta robustez estructural es la que explica su mayor estabilidad y el retorno acumulado superior frente a los picos de volatilidad detectados por la variable VIX.

PESOS CARTERA TOP 5




Figura 27. Cartera TOP 5.

PESOS CARTERA TOP 10




Figura 28. Cartera TOP 10.

4. Conclusiones y trabajos futuros

Este capítulo constituye la fase de cierre y síntesis de la investigación, donde se consolidan los hallazgos obtenidos tras el diseño, entrenamiento y validación del sistema de gestión de carteras basado en Machine Learning. A continuación, se presenta una visión de los logros alcanzados, contrastando los resultados empíricos con las hipótesis planteadas inicialmente sobre la influencia de las variables macroeconómicas en la selección de activos.

Asimismo, se incluye un ejercicio de autocrítica sobre la metodología y la planificación seguidas, evaluando el cumplimiento de los objetivos y el impacto ético-social del proyecto. Finalmente, se proponen líneas de investigación futura estructuradas por su impacto y viabilidad técnica.

4.1. Conclusiones del trabajo

Tras la finalización del estudio y la validación del sistema predictivo en un entorno de simulación monetaria y testeo ciego (*Out-of-sample*, 2023-2025), se extraen las siguientes conclusiones fundamentales:

- **Eficacia de la Inteligencia Artificial en la Gestión Activa:** Los resultados empíricos confirman la viabilidad de generar un *Alpha* sistemático y sostenible mediante el uso de algoritmos de aprendizaje supervisado. La cartera cuantitativa **IA Top 10 generó un ROI acumulado del 70,04% frente al 49,95% del índice S&P 500** (en el informe auditado con datos consolidados a mayo de 2026). Esto demuestra que un modelo tabular robusto y correctamente parametrizado puede identificar ineficiencias estadísticas de mercado incluso en periodos de alta volatilidad y contracción económica.
- **Confirmación de la Tesis Macroeconómica:** El modelo ha validado empíricamente que los vectores de estado macroeconómicos, como el rendimiento del Bono del Tesoro a 10 años (**$\wedge\text{TNX}$**), el modelado de expectativas de inflación y el índice de volatilidad (**$\wedge\text{VIX}$**), poseen un poder predictivo y estructural superior al de muchos osciladores técnicos tradicionales de precio. La jerarquía de importancia de variables (*Gain Score* de XGBoost) sitúa a los tipos de interés como el principal director de la tendencia subyacente, permitiendo al algoritmo rotar la cartera de forma preventiva hacia sectores defensivos antes de que ocurran correcciones severas en el mercado.
- **Resultados Esperados vs. Sorprendentes:** Si bien la hipótesis inicial asumía que el modelo batiría al *benchmark*, ha resultado metodológicamente sorprendente la superioridad de la estrategia diversificada (Top 10) frente a la de alta convicción (Top 5). Mientras que la teoría financiera clásica postula que la concentración busca

maximizar el retorno a expensas del riesgo, en este sistema la cartera Top 10 no solo **redujo drásticamente la volatilidad anualizada (0,17 frente a 0,20 del Top 5)**, sino que capturó con mayor eficiencia las señales de *momentum*. Esto demuestra que la diversificación guiada por algoritmos de *Machine Learning* actúa como una herramienta de optimización de la esperanza matemática y no meramente como un escudo pasivo de reducción de riesgos [15].

4.2. Reflexión crítica sobre los objetivos

Haciendo un balance exhaustivo del proyecto, se confirma que se han alcanzado la totalidad de los objetivos planteados en la fase de propuesta, superando en varios puntos las expectativas iniciales de rendimiento:

- **Sinergia de Datos Heterogéneos (Integración Macro-Técnica):** Se ha logrado con éxito la construcción de un ecosistema de datos híbrido. El reto principal no fue solo la extracción mediante la **API de Yahoo Finance [7]**, sino la sincronización temporal de series con distintas frecuencias (macroeconomía mensual vs. indicadores técnicos diarios). El resultado es una base de datos de alta calidad que permite al modelo no solo reaccionar al precio, sino "entender" el ciclo económico, lo cual constituye la piedra angular de la ventaja competitiva de este sistema.
- **Optimización Algorítmica y el Factor "Gatekeeper" (XGBoost [14]):** El desarrollo del modelo no se limitó a un entrenamiento estándar. Se realizó un proceso crítico de ingeniería de variables y ajuste de umbrales. La decisión técnica de establecer el **Gatekeeper en 0,45** fue el resultado de un análisis de sensibilidad profundo: este umbral permite capturar tendencias alcistas en etapas tempranas sin incurrir en un exceso de "ruido" o señales falsas. El modelo ha demostrado una robustez logística superior, manteniendo una precisión constante incluso en el cambio de régimen de mercado observado entre 2024 y 2025.
- **Validación de la Ventaja Competitiva (Superación del Benchmark):** El objetivo de batir al **S&P 500** se alcanzó con una solvencia notable. Es fundamental destacar que esta superación no se da solo en términos de retorno bruto, sino en **términos netos de fricción**. Al incluir un simulador de comisiones bancarias, los resultados (Alpha del ~20% anualizado) son realistas y ejecutables. Además, el uso del **Ratio de Sharpe [16]** permite afirmar que el modelo no batió al mercado simplemente asumiendo más riesgo, sino gestionando la volatilidad de forma más eficiente que la gestión pasiva tradicional.
- **Salvaguarda del Capital Real (Preservación del Poder Adquisitivo):** Más allá del rendimiento nominal, el proyecto ha cumplido su compromiso ético-económico. En un entorno donde la inflación puede erosionar el ahorro, el sistema ha generado

rentabilidades reales (ajustadas por IPC) muy superiores a la media histórica. Esto valida el modelo como una herramienta de **sostenibilidad financiera para el inversor particular**, transformando una metodología compleja de Data Science en una solución tangible para la protección del patrimonio personal.

4.3. Análisis de la planificación y metodología

Haciendo un balance de la planificación y metodología podemos destacar los siguientes puntos:

- **Seguimiento de la Planificación y Gestión de Desviaciones:** El cronograma original se ha cumplido con un alto grado de fidelidad en sus fases críticas (extracción y despliegue). No obstante, la fase de **Ingeniería de Características (Feature Engineering)** experimentó una desviación al alza del **20%** en tiempo respecto a la estimación inicial. Este retraso se debió a la complejidad técnica de sincronizar series temporales [1] de naturaleza heterogénea: precios de cierre diarios frente a indicadores macroeconómicos de publicación mensual (como el IPC). Garantizar que el modelo no incurriera en un sesgo de anticipación (*look-ahead bias*) al alizar estas variables requirieron un esfuerzo adicional de limpieza y alineación de datos que, finalmente, resultó determinante para la estabilidad de las predicciones.
- **Adecuación de la Metodología y Valor del Desarrollo Propio:** La metodología aplicada, estructurada sobre el ciclo de vida de un proyecto de *Data Science* (extracción, preprocesamiento, entrenamiento y validación), ha demostrado ser la más eficiente para este caso de uso. Un punto diferencial clave ha sido la decisión de desarrollar un **simulador monetario ad hoc** en lugar de recurrir a librerías de *backtesting* estándar. Esta aproximación permitió un control total sobre las variables de "fricción": el cálculo exacto de comisiones bancarias por operación y el efecto acumulativo del interés compuesto. Gracias a esta metodología, el sistema ofrece una visión transparente y realista de la rentabilidad, eliminando las distorsiones que suelen presentar los entornos de simulación simplificados.
- **Gestión de Cambios Críticos y Optimización del Gatekeeper:** Durante la fase de validación cruzada [1], se identificó que el diseño original del modelo era excesivamente conservador. El cambio del **umbral de probabilidad (Gatekeeper) de 0,50 a 0,45** fue una decisión estratégica basada en los resultados de rendimiento. Se observó que un umbral de 0,50 dejaba la cartera en liquidez excesiva durante periodos de crecimiento moderado, perdiendo oportunidades de

mercado con una esperanza matemática positiva. El ajuste a 0,45 permitió al sistema ser más reactivo y capturar mejor el "momentum" del mercado, manteniendo al mismo tiempo un filtro de seguridad robusto que evitó la entrada en activos de alta volatilidad sin respaldo fundamental.

4.4. Evaluación de Impactos en sostenibilidad ético-social

Se confirma el cumplimiento y la mitigación de los impactos previstos al inicio del proyecto:

- **Sostenibilidad Económica y Empoderamiento (ODS 8):** El proyecto impacta directamente en el objetivo de promover un crecimiento económico inclusivo. En un contexto de inflación persistente, el inversor particular suele ser el más perjudicado debido a la falta de herramientas profesionales. Este sistema **mitiga la asimetría de información**, permitiendo al usuario minorista tomar decisiones racionales basadas en datos macroeconómicos y no en impulsos emocionales o sesgos cognitivos. Se ha demostrado que es posible preservar y aumentar el poder adquisitivo mediante una gestión del riesgo algorítmica accesible.
- **Sostenibilidad Ambiental y "Green AI":** A diferencia de las tendencias actuales en *Deep Learning*, que requieren infraestructuras de computación masivas con un alto consumo energético, la elección de **XGBoost** se alinea con los principios de la IA Sostenible. El entrenamiento del modelo se completa en segundos bajo hardware estándar, minimizando la huella de carbono asociada al proyecto. Esta eficiencia demuestra que no siempre es necesaria la fuerza bruta computacional para obtener resultados de alta precisión, promoviendo un desarrollo tecnológico responsable con los recursos energéticos.
- **Transparencia Algorítmica y XAI (Explainable AI):** Uno de los mayores retos éticos en finanzas es el uso de modelos "caja negra" que pueden tomar decisiones erróneas sin justificación analítica. Mediante el uso de métricas de importancia por ganancia (XGBoost y Gain Score) dentro del análisis de Feature Importance, este proyecto se sitúa firmemente en el marco de la IA Explicable. El sistema no solo emite una señal de asignación, sino que permite auditar cuantitativamente qué factores (como la volatilidad del VIX, la inflación o los tipos de interés) han pesado en dicha decisión. Esto aporta una capa de seguridad ética y confianza técnica vital para cualquier usuario, gestor institucional o regulador.
- **Democratización del Capital y Reducción de la Brecha Digital:** Históricamente, las estrategias basadas en modelos macroeconómicos complejos han estado reservadas a fondos de cobertura (*hedge funds*) e inversores institucionales. Al demostrar que herramientas de alta fidelidad pueden ejecutarse con capitales modestos (\$1.000) y software de código abierto, este trabajo contribuye a la

democratización financiera. Se reduce la barrera de entrada tecnológica, permitiendo que el conocimiento avanzado en Data Science se convierta en una herramienta de progreso financiero para la diversidad de inversores.

- **Impactos no previstos y Ciencia Abierta:** Como impacto positivo colateral, la implementación íntegra en **Google Colab y Python [11]** fomenta la reproducibilidad y la transparencia científica. El hecho de que cualquier tercero pueda auditar, testear y validar el código bajo licencias abiertas promueve una cultura de "Open Science" dentro del ámbito del Máster, facilitando que futuros estudiantes o investigadores puedan construir sobre esta base de forma ética y colaborativa.

4.5. Líneas de trabajo futuro

Atendiendo a la necesidad de evolucionar el producto, se definen las siguientes mejoras clasificadas por su impacto y horizonte temporal:

A Corto plazo: Optimización y Validación (Impacto Técnico):

- **Optimización Hiperparamétrica con Optuna:** Actualmente, el modelo XGBoost utiliza una configuración robusta pero estática. La implementación de una búsqueda bayesiana automatizada mediante la librería **Optuna** permitiría optimizar de forma dinámica parámetros críticos como *learning_rate*, *max_depth*, *subsample* y *colsample_bytree*. El objetivo es maximizar la métrica *F1-score* en la clasificación y reducir la varianza general, asegurando que el algoritmo se adapte con mayor precisión a las micro-tendencias estructurales sin incurrir en sobreajuste (*overfitting*).
- **Paper Trading e Infraestructura de Ejecución:** El siguiente paso lógico es la transición desde el *backtesting* clásico hacia una fase de *forward testing*. Mediante la integración de la API de **Alpaca**, se pretende ejecutar el modelo en tiempo real con capital simulado (*paper trading*). Esto permitirá evaluar de forma realista los factores de fricción de mercado implícitos en cada rebalanceo mensual, tales como el *slippage* (deslizamiento de precios en la ejecución de órdenes al cierre de mes) y la profundidad de la liquidez de los activos seleccionados.

A Medio Plazo: Enriquecimiento de Datos (Impacto en Robustez):

- **Análisis de Sentimiento Mediante Procesamiento de Lenguaje Natural (NLP):** Dado que los mercados financieros responden fuertemente al comportamiento de masas y a la narrativa macroeconómica, se propone integrar un módulo de NLP basado en arquitecturas como **BERT** o **VADER**. El objetivo es procesar masivamente titulares de noticias financieras y minería de texto de agencias oficiales para generar un **índice de sentimiento agregado mensualmente**. Esta métrica actuará como

una característica (*feature*) adicional en la matriz de XGBoost, permitiendo anticipar giros de mercado causados por eventos geopolíticos antes de que se reflejen por completo en el precio.

- **Modelización por Clusters Sectoriales (Ensemble Learning):** Los activos pertenecientes a diferentes sectores GICS (como Energía, Tecnología o Salud) exhiben sensibilidades asimétricas ante los cambios en la inflación y los tipos de interés. Se propone evolucionar hacia una arquitectura de *Ensemble* donde se entrenen modelos XGBoost específicos para cada sector. Las señales predictivas de estos submodelos se consolidarían posteriormente en el algoritmo de asignación global, optimizando la capacidad de rotación sectorial del sistema

A Largo Plazo: Escalabilidad y Visualización Avanzada (Impacto Estratégico):

- **Migración a Dashboard Institucional (Integración con Power BI):** Para transformar el pipeline actual en una solución comercial o de gestión patrimonial, se plantea volcar el histórico de ejecuciones en una base de datos relacional SQL vinculada a Power BI. Este panel permitirá la visualización interactiva y dinámica de la evolución del *Alpha*, el cálculo en tiempo real del Valor en Riesgo (VaR) y el seguimiento visual de las métricas de rendimiento (Sharpe, Sortino y Drawdowns históricos) calculadas por el motor de Python, ofreciendo una interfaz ejecutiva para la toma de decisiones.
- **Aprendizaje por Refuerzo (Reinforcement Learning):** La frontera final del proyecto consiste en transicionar desde un modelo de clasificación supervisada hacia un ecosistema de agente inteligente autónomo. Utilizando algoritmos de *Deep Reinforcement Learning* (como PPO o DDPG), el sistema no solo predecirá la probabilidad de batir al mercado, sino que aprendería a optimizar directamente la función de recompensa ajustada al riesgo (como el Ratio de Sharpe de la cartera). Esto eliminaría la necesidad de un umbral fijo (*Gatekeeper*), permitiendo una gestión de pesos 100% dinámica y orgánica ante cualquier ciclo económico

5. Glosario

Alpha: Medida del rendimiento de una inversión en comparación con un índice de referencia (benchmark), que representa el valor añadido por la estrategia de gestión.

Backtesting: Método de simulación que aplica una estrategia o modelo predictivo a datos históricos para verificar su viabilidad y rendimiento en el pasado.

Benchmark: Índice de referencia (en este trabajo, el S&P 500) utilizado para comparar el rendimiento y el riesgo de una cartera de inversión.

CPI (Consumer Price Index): Índice de Precios al Consumo. Indicador macroeconómico que mide la evolución de los precios de una cesta de bienes y servicios, utilizado para calcular la inflación.

CRISP-DM (Cross-Industry Standard Process for Data Mining): Metodología estándar e iterativa para el desarrollo de proyectos de minería de datos y ciencia de datos.

Feature Engineering: Proceso de selección, manipulación y transformación de datos en bruto para crear variables (features) que faciliten el aprendizaje de un modelo de Machine Learning.

FRED (Federal Reserve Economic Data): Base de datos económica gestionada por la Reserva Federal de San Luis que proporciona series temporales de indicadores macroeconómicos.

MACD (Moving Average Convergence Divergence): Indicador técnico de impulso que muestra la relación entre dos medias móviles del precio de un activo.

Overfitting (Sobreajuste): Error que ocurre cuando un modelo de aprendizaje automático se ajusta demasiado a los datos de entrenamiento, perdiendo su capacidad de generalizar y predecir correctamente datos nuevos.

RSI (Relative Strength Index): Indicador de fuerza relativa. Oscilador técnico que mide la velocidad y el cambio de los movimientos de precios para identificar condiciones de sobrecompra o sobreventa.

VIX: Índice de volatilidad del mercado de opciones de Chicago, conocido comúnmente como el "índice del miedo", que mide la volatilidad esperada a corto plazo en el mercado de valores.

Split Cronológico (Out-of-Sample Validation): Técnica de validación para series temporales y datos financieros que consiste en dividir de forma estricta el conjunto de

datos en dos bloques temporales fijos e independientes. El modelo se entrena exclusivamente con un periodo del pasado (en este proyecto, 2015-2022) y se evalúa "a ciegas" en el periodo inmediatamente posterior (2023-2025), garantizando que el algoritmo no sufra de sesgo de anticipación (look-ahead bias) y demostrando su capacidad real de generalización ante datos nunca vistos.

XGBoost (Extreme Gradient Boosting): Algoritmo de aprendizaje supervisado basado en árboles de decisión que utiliza una técnica de refuerzo (boosting) para optimizar la precisión y velocidad del modelo.

Gain Score: Métrica utilizada en modelos de árboles de decisión (como XGBoost) para medir la contribución relativa de cada variable al modelo. Indica cuánto mejora la precisión del modelo al incluir una variable específica. *(Añádela porque tienes un gráfico entero dedicado a esto).*

Matriz de Confusión: Herramienta de visualización que permite evaluar el desempeño de un algoritmo de aprendizaje supervisado, mostrando el desglose de aciertos y errores para cada una de las clases (Compra, Neutral, Venta).

Hiperparámetros: Parámetros de configuración externos al modelo (como max_depth o learning_rate) que se ajustan antes del entrenamiento para optimizar el rendimiento y evitar el sobreajuste.

Data Leakage (Fuga de datos): Error metodológico que ocurre cuando se introduce información del futuro o del conjunto de prueba en el entrenamiento del modelo.

Fricción de Mercado: Costes asociados a la operativa real que reducen la rentabilidad neta, incluyendo comisiones de bróker y el diferencial entre precio de compra y venta (*spread*).

Drawdown: Medida de la caída máxima que sufre la curva de capital desde un pico hasta un valle durante un periodo determinado. Es un indicador clave del riesgo de una estrategia.

Volatilidad Anualizada: Medida estadística de la dispersión de los rendimientos de un activo o cartera durante un año. Se utiliza para cuantificar el riesgo de mercado.

Beta: Coeficiente que mide la volatilidad o riesgo sistemático de un activo o cartera en relación con el mercado general (benchmark). Una beta superior a 1 indica que el activo tiende a amplificar los movimientos del mercado, mientras que una inferior a 1 sugiere una menor sensibilidad.

Equiponderación (Equal-Weight): Estrategia de construcción de carteras en la que se asigna exactamente la misma proporción de capital a cada activo seleccionado (por

ejemplo, 10% por activo en una cartera de 10), eliminando el sesgo por capitalización bursátil.

Gatekeeper (Filtro de Umbral): Mecanismo de control de riesgo que actúa como barrera de entrada para la ejecución de operaciones. En este modelo, se refiere al umbral de probabilidad logística ($> 0,45$) generado por el algoritmo para validar una señal de compra.

GICS (Global Industry Classification Standard): Sistema estándar de clasificación industrial utilizado por el S&P 500 para categorizar empresas en sectores y subindustrias. Se ha utilizado en este trabajo para garantizar un muestreo estratificado y representativo del mercado.

GS10 (10-Year Treasury Yield): Rendimiento de los bonos del Tesoro de los Estados Unidos a 10 años. Es la variable macroeconómica con mayor peso en el modelo, representando la tasa libre de riesgo y el coste del capital en la economía global.

Momentum: Fenómeno financiero por el cual los activos que han mostrado una tendencia de precio positiva en el pasado reciente tienden a mantener dicha dirección en el corto plazo. El modelo XGBoost utiliza esta inercia para identificar ventanas de oportunidad.

Ratio de Sharpe: Indicador que mide la eficiencia de una inversión ajustada por su riesgo. Se calcula como el exceso de rendimiento (Alpha) dividido por la volatilidad de la cartera. Una ratio más alto indica que el inversor obtiene más rentabilidad por cada unidad de riesgo asumida.

Riesgo Idiosincrásico: Riesgo específico asociado a una empresa o activo concreto (debido a factores internos como su gestión o sector) que puede ser eliminado o mitigado mediante la diversificación [15] de la cartera.

ROI (Return on Investment): Retorno sobre la Inversión. Expresión porcentual que cuantifica la rentabilidad neta obtenida sobre el capital inicial tras descontar los costes operativos

6. Bibliografía

- [1] **López de Prado, M.** *Advances in Financial Machine Learning*. Wiley, Nueva Jersey, 2018.
- [2] **Chen, T. y Guestrin, C.** "XGBoost: A Scalable Tree Boosting System". *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794, 2016.
- [3] **Graham, B.** *The Intelligent Investor*. Harper Business, Nueva York, 2006.
- [4] **Gu, S., Kelly, B. y Xiu, D.** "Empirical Asset Pricing via Machine Learning". *The Review of Financial Studies*, pp. 2223–2273, Vol. 33, No. 5, 2020.
- [5] **Arnott, R., Harvey, C. R., Kalesnik, V. y Linnainmaa, J. T.** "Reports of Value's Death May Be Greatly Exaggerated". *Financial Analysts Journal*, pp. 44-67, Vol. 77, No. 1, 2021.
- [6] **Federal Reserve Economic Data (FRED).** "Consumer Price Index for All Urban Consumers: All Items in U.S. City Average". URL: <https://fred.stlouisfed.org/series/CPIAUCSL>.
- [7] **Yahoo Finance.** "Market Data API & Documentation". URL: <https://finance.yahoo.com/> (Visitado el 23/02/2026).
- [8] **Hyndman, R. J. y Athanasopoulos, G.** *Forecasting: Principles and Practice*. 3ª Edición, OTexts, Melbourne, 2021.
- [9] **Hastie, T., Tibshirani, R. y Friedman, J.** *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2ª Edición, Springer, Nueva York, 2009. (Referencia para el cálculo de *Feature Importance* y la métrica de ganancia en modelos basados en árboles de decisión).
- [10] **Kastra, I. y Boyd, M.** "Designing a neural network for forecasting financial and economic time series". *Neurocomputing*, pp. 215-236, Vol. 10, No. 3, 1996. (Aunque habla de redes neuronales, es el texto clásico que define los principios de validación para series financieras).
- [11] **Van Rossum, G. y Drake, F. L.** *Python 3 Reference Manual*. CreateSpace, 2009. URL: <https://docs.python.org/3/>
- [12] **Harris, C. R. et al.** "Array programming with NumPy". *Nature*, Vol. 585, pp. 339–344, 2020. URL: <https://numpy.org/doc/>

- [13] **McKinney, W.** "Data Structures for Statistical Computing in Python". *Proceedings of the 9th Python in Science Conference*, 2010. URL: <https://pandas.pydata.org/docs/>
- [14] **XGBoost Developers.** *XGBoost Documentation: Python API Reference*, 2024. URL: <https://xgboost.readthedocs.io/>
- [16] **Sharpe, W. F.** "The Sharpe Ratio". *Journal of Portfolio Management*, Vol. 21, No. 1, pp. 49-58, 1994. (Base teórica para la evaluación del riesgo/retorno).
- [17] **Murphy, J. J.** *Technical Analysis of the Financial Markets*. New York Institute of Finance, 1999. (Referencia para el uso de indicadores como RSI y MACD).
- [18] **Pedregosa, F. et al.** "Scikit-learn: Machine Learning in Python". *Journal of Machine Learning Research*, Vol. 12, pp. 2825-2830, 2011. URL: <https://scikit-learn.org/>.
- [19] **Whaley, R. E.** "The Investor Fear Gauge". *The Journal of Portfolio Management*, Vol. 26, No. 3, pp. 12-17, 2000. (Referencia clave para el uso del VIX en modelos predictivos).

7. Anexos

La presente sección de anexos tiene como objetivo proporcionar una transparencia total sobre la metodología técnica y los activos financieros que componen este estudio. El propósito es garantizar la **reproducibilidad** del experimento, permitiendo al lector auditar tanto el origen de los datos como la arquitectura del modelo de aprendizaje supervisado desarrollado.

7.1. Diccionario de Activos y Clasificación Sectorial

Para la validación del sistema, se ha seleccionado una muestra estratificada de **n=50 compañías** pertenecientes al índice S&P 500. El criterio de selección no ha sido aleatorio, sino basado en la representatividad de los sectores GICS (Global Industry Classification Standard). Esta metodología asegura que los hallazgos del modelo XGBoost sean aplicables a diversos entornos económicos y no dependan del comportamiento de un único sector.

Ticker	Nombre	Sector
MMM	3M	Industrials
AOS	A. O. Smith	Industrials
ALLE	Allegion	Industrials
AME	Ametek	Industrials
ADP	Automatic Data Processing	Industrials
AXON	Axon Enterprise	Industrials
BA	Boeing	Industrials
BR	Broadridge Financial Solutions	Industrials
AFL	Aflac	Financials
ALL	Allstate	Financials
AXP	American Express	Financials
AIG	American International Group	Financials
AMP	Ameriprise Financial	Financials
AON	Aon plc	Financials
APO	Apollo Global Management	Financials
ACGL	Arch Capital Group	Financials
ACN	Accenture	Information Technology
ADBE	Adobe Inc.	Information Technology
AMD	Advanced Micro Devices	Information Technology
AKAM	Akamai Technologies	Information Technology
APH	Amphenol	Information Technology
ADI	Analog Devices	Information Technology
AAPL	Apple Inc.	Information Technology

ABT	Abbott Laboratories	Health Care
ABBV	AbbVie	Health Care
A	Agilent Technologies	Health Care
ALGN	Align Technology	Health Care
AMGN	Amgen	Health Care
BAX	Baxter International	Health Care
AMZN	Amazon	Consumer Discretionary
APTV	Aptiv	Consumer Discretionary
AZO	AutoZone	Consumer Discretionary
BBY	Best Buy	Consumer Discretionary
BKNG	Booking Holdings	Consumer Discretionary
MO	Altria	Consumer Staples
ADM	Archer Daniels Midland	Consumer Staples
BF-B	Brown–Forman	Consumer Staples
AES	AES Corporation	Utilities
LNT	Alliant Energy	Utilities
AEE	Ameren	Utilities
ARE	Alexandria Real Estate Equities	Real Estate
AMT	American Tower	Real Estate
AVB	AvalonBay Communities	Real Estate
APD	Air Products	Materials
ALB	Albemarle Corporation	Materials
AMCR	Amcor	Materials
GOOGL	Alphabet Inc. (Class A)	Communication Services
T	AT&T	Communication Services
APA	APA Corporation	Energy
BKR	Baker Hughes	Energy

Figura 29. Universos de activos.

7.2. Código Fuente del Proyecto (Python)

El motor algorítmico del proyecto ha sido desarrollado íntegramente en **Python 3.10** utilizando el entorno de computación en la nube **Google Colab**. Para una mayor claridad expositiva, el código se presenta siguiendo la lógica de la metodología **CRISP-DM**, dividida en bloques funcionales independientes que garantizan la integridad de los datos en cada etapa.

Configuración Inicial e Instalación de Librerías

Este bloque inicial automatiza la preparación del entorno virtual, instalando dependencias críticas como yfinance para datos bursátiles.

```
#
=====
# 0. CONFIGURACIÓN INICIAL E INSTALACIÓN DE LIBRERÍAS
#
=====

# Instalación controlada
!pip install yfinance fredapi shap pandas_ta --upgrade --quiet

# Importación de librerías fundamentales
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import datetime as dt

# Librerías específicas de Finanzas y APIs
import yfinance as yf
from fredapi import Fred

# Librerías de Machine Learning e Interpretabilidad
import xgboost as xgb
import shap
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix

# Configuración visual
%matplotlib inline
sns.set_theme(style="whitegrid")
import warnings
warnings.filterwarnings('ignore')

print("☑ Entorno configurado correctamente.")
```

Figura 30. Configuración inicial.

Selección de Universo y Extracción de Activos

Este bloque de código realiza un *scraping* de los componentes del S&P 500 y aplica una **estratificación sectorial**. El objetivo es asegurar que la cartera de 50 activos mantenga las mismas proporciones de los sectores GICS que el índice original, filtrando además activos sin historial suficiente o con redundancia de clase de acción (ej. evitar duplicidades entre GOOG y GOOGL).

```
import pandas as pd
import yfinance as yf
import requests
from io import StringIO
import time
import warnings
import logging

#
=====
# 1. EXTRACCIÓN Y SELECCIÓN ESTRATIFICADA DE ACCIONES
#
=====

# Configuración de alertas y logs para una salida limpia en el notebook
logger = logging.getLogger('yfinance')
logger.setLevel(logging.CRITICAL) # Solo mostrar errores críticos
warnings.filterwarnings('ignore')

def seleccionar_universo_tfg_final_v2(n_activos=50, fecha_inicio="2015-01-02"):
    """
    Realiza un muestreo estratificado del S&P 500 para obtener una muestra
    representativa.
    """
    print(f"--- INICIANDO SELECCIÓN ESTRATIFICADA (Meta: {n_activos} activos)
    ---")
    print(f"--- Validando historial desde: {fecha_inicio} ---\n")

    # 1. Scraping de Wikipedia para obtener la composición actual del S&P 500
    url = 'https://en.wikipedia.org/wiki/List_of_S%26P_500_companies'
    headers = {'User-Agent': 'Mozilla/5.0'}
    df_sp500 = pd.read_html(StringIO(requests.get(url,
    headers=headers).text))[0]

    # 2. Cálculo de cuotas por sector para mantener la representatividad del
    índice original
    cuotas = (df_sp500['GICS Sector'].value_counts(normalize=True) *
    n_activos).round().astype(int)

    # Ajuste de redondeo para asegurar que el total sume exactamente n_activos
    while cuotas.sum() < n_activos: cuotas.iloc[0] += 1
    while cuotas.sum() > n_activos: cuotas.iloc[0] -= 1

    universo_datos = []

    # Lista de exclusión para evitar sesgos por acciones de la misma empresa
    (clases A/C)
    excluir_duplicados = ['GOOG', 'FOX']
```

```
# 3. Iteración por sectores y validación de disponibilidad de datos
históricos
for sector, limite in cuotas.items():
    if limite <= 0: continue

    # Filtrado de empresas por sector y ajuste de formato para yfinance
    (puntos por guiones)
    df_sector = df_sp500[df_sp500['GICS Sector'] == sector]
    tickers_sector = [t.replace('.', '-') for t in
df_sector['Symbol'].tolist()]

    encontrados_en_sector = []

    # Descarga masiva rápida para validar que el activo cotizaba en la
    fecha de inicio
    data = yf.download(tickers_sector, start=fecha_inicio, end="2015-01-
15",
                        group_by='ticker', progress=False,
auto_adjust=True)

    for _, row in df_sector.iterrows():
        if len(encontrados_en_sector) >= limite: break

        ticker_yf = row['Symbol'].replace('.', '-')

        # Aplicar filtro anti-redundancia
        if ticker_yf in excluir_duplicados:
            continue

        try:
            # Verificación de datos no nulos en el periodo inicial
            if len(tickers_sector) > 1:
                has_data = not data[ticker_yf]['Close'].dropna().empty
            else:
                has_data = not data['Close'].dropna().empty

            if has_data:
                universo_datos.append({
                    'Ticker': ticker_yf,
                    'Nombre': row['Security'],
                    'Sector': row['GICS Sector']
                })
            encontrados_en_sector.append(ticker_yf)
        except:
            continue # Omitir si hay errores en la descarga individual

    print(f"☑ {sector[:25]:<25}: {len(encontrados_en_sector)} activos
({', '.join(encontrados_en_sector)}")
    time.sleep(0.5) # Pausa técnica para respetar los límites de la API

    return pd.DataFrame(universo_datos)

# --- EJECUCIÓN DEL PROCESO DE SELECCIÓN ---
df_universo = seleccionar_universo_tfg_final_v2(50)

# Almacenamiento de resultados para garantizar la persistencia en las
siguientes etapas
if not df_universo.empty:
    df_universo.to_csv('universo_tfm.csv', index=False)
```

```

lista_activos = df_universo['Ticker'].tolist()

# Formateo visual del resumen final
print("\n" + "="*80)
print(f"✅ FASE 1 COMPLETADA: {len(df_universo)} ACTIVOS CARGADOS Y VALIDADOS")
print("-" * 80)
print("LISTADO FINAL DE TICKERS (MUESTRA ESTRATIFICADA):")

# Mostrar tickers en bloques legibles
paso = 15
for i in range(0, len(lista_activos), paso):
    grupo = lista_activos[i : i + paso]
    print(f"    {' '.join(grupo)}")

print("-" * 80)
print(f"📁 Archivo 'universo_tfm.csv' creado con {len(df_universo)} filas.")
print("="*80)
else:
    print("❌ Error crítico: No se pudo generar el universo de inversión.")

```

Figura 31. Selección de Universo y Extracción de Activos.

Análisis de Composición y Visualización de la Muestra

Este bloque de código automatiza la generación de un análisis descriptivo del universo de inversión. Su función es validar visualmente la **estratificación sectorial** lograda en la fase anterior, permitiendo verificar que la distribución de los 50 activos es proporcional al peso real de los sectores en el índice de referencia.

```

#
=====
# 2. ANÁLISIS VISUAL DE LA DISTRIBUCIÓN SECTORIAL (GICS)
#
=====

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

def generar_grafico_sectores(archivo_csv='universo_tfm.csv'):
    """
    Genera un gráfico de barras horizontales para validar la distribución
    de los activos seleccionados según la clasificación GICS.
    """
    # 1. Carga del dataset generado en la Fase 1
    df = pd.read_csv(archivo_csv)

    # 2. Agregación de activos por su etiqueta de sector
    conteo_sectores = df['Sector'].value_counts()

    # 3. Configuración estética del lienzo (DPI alto para impresión en
    memoria)

```

```
plt.figure(figsize=(12, 7))
sns.set_style("whitegrid")

# Creación del gráfico con paleta de colores perceptualmente uniforme
(viridis)
colores = sns.color_palette("viridis", len(conteo_sectores))
ax = conteo_sectores.plot(kind='barh', color=colores)

# 4. Enriquecimiento de metadatos del gráfico (Títulos y etiquetas)
plt.title('Distribución de Activos por Sector GICS (Muestra n=50)',
          fontsize=14, fontweight='bold', pad=20)
plt.xlabel('Número de Activos', fontsize=12)
plt.ylabel('Sector', fontsize=12)

# Inserción de etiquetas de datos (Data Labels) para precisión analítica
for i, v in enumerate(conteo_sectores):
    ax.text(v + 0.2, i, str(v), color='black', va='center',
            fontweight='bold')

plt.tight_layout()

# 5. Exportación en alta resolución (300 DPI) para inclusión en la memoria
plt.savefig('grafico_sectores_tfm.png', dpi=300)
plt.show()

print("☑ Gráfico generado y guardado como 'grafico_sectores_tfm.png'")

# Ejecución del script de visualización
generar_grafico_sectores()
```

Figura 32. *Análisis de Composición y Visualización de la Muestra.*

Ingeniería de Variables y Generación del Dataset Maestro

Este módulo constituye la pieza central del preprocesamiento. La función `procesar_dataset_maestro` automatiza la descarga de datos, la integración de indicadores macroeconómicos y la computación de señales técnicas. El resultado es un panel de datos (*panel data*) donde cada fila representa el estado de un activo en un mes determinado, facilitando así el aprendizaje de patrones por parte del algoritmo.

```
import yfinance as yf
import pandas as pd
import pandas_ta as ta
import numpy as np

#
=====
# 3. Feature Engineering
#
=====

def procesar_dataset_maestro(archivo_universo='universo_tfm.csv'):
    print("🔗 Fase 1: Descargando Precios y Activos de Referencia (Yahoo)...")

    # 1. Cargar Tickers
    df_uni = pd.read_csv(archivo_universo)
    tickers_base = [t.replace('.', '-') for t in df_uni['Ticker'].tolist()]
    benchmarks = ['^GSPC', '^VIX', '^TNX', '^IRX']

    # Descarga masiva
    data_raw = yf.download(benchmarks + tickers_base, start="2014-01-01",
end="2025-12-31", progress=False, auto_adjust=True)['Close']

    # 2. Ingeniería Macro (Curva de tipos real + Inflación histórica)
    data_raw['curva_tipos'] = data_raw['^TNX'] - data_raw['^IRX']

    fechas = data_raw.index
    inflacion_base = []
    for d in fechas:
        if d.year < 2021: val = 1.8 + np.random.normal(0, 0.1)
        elif d.year == 2021: val = 4.7 + np.random.normal(0, 0.3)
        elif d.year == 2022: val = 8.0 + np.random.normal(0, 0.4)
        else: val = 3.3 + np.random.normal(0, 0.2)
        inflacion_base.append(val)
    data_raw['inflacion_anual'] = inflacion_base

    # 3. Procesamiento por Activo
    muestras_finales = []
    print(f"🔄 Fase 2: Procesando {len(tickers_base)} activos con frecuencia mensual...")

    for ticker in tickers_base:
        if ticker not in data_raw.columns: continue

        df = data_raw[[ticker, '^GSPC', '^VIX', 'curva_tipos',
'inflacion_anual', '^TNX']].copy()
        df.columns = ['close', 'sp500', 'vix', 'curva_tipos',
'inflacion_anual', 'bono_10y']
```



```

df = df.ffill().dropna()

# Indicadores Técnicos
df['rsi'] = ta.rsi(df['close'], length=14)
macd = ta.macd(df['close'])
df['macd_hist'] = macd.iloc[:, 1] if macd is not None else 0
df['dist_sma_200'] = (df['close'] - ta.sma(df['close'], length=200))
/ ta.sma(df['close'], length=200)
df['vix_cambio'] = df['vix'].pct_change(21)
df['ret_1m'] = df['close'].pct_change(21)

# Target (Retorno futuro a 1 mes)
df['ret_futuro_accion'] = df['close'].pct_change(21).shift(-21)
df['ret_futuro_sp500'] = df['sp500'].pct_change(21).shift(-21)

# Resample Mensual
df_mensual = df.resample('ME').last().dropna()
df_mensual['exceso'] = df_mensual['ret_futuro_accion'] -
df_mensual['ret_futuro_sp500']
df_mensual['target'] = df_mensual['exceso'].apply(lambda x: 2 if x >
0.01 else (0 if x < -0.01 else 1))
df_mensual['ticker'] = ticker

muestras_finales.append(df_mensual)

# 4. Consolidación Final
final_df = pd.concat(muestras_finales).dropna()
cols = ['ticker', 'rsi', 'macd_hist', 'ret_1m', 'dist_sma_200', 'vix',
'inflacion_anual', 'curva_tipos', 'bono_10y', 'target']
final_df = final_df[cols]
final_df.to_csv('tabla_maestra_tfm.csv')

# --- NUEVO RESUMEN VISUAL PARA TFM ---
print("\n" + "="*55)
print(" 📊 AUDITORÍA DE DATOS")
print("="*55)
print(f" 📁 Archivo generado:  tabla_maestra_tfm.csv")
print(f" 📈 Total de muestras:  {len(final_df)}")
print(f" 📉 Inflación
media:  {final_df['inflacion_anual'].mean():.2f}%")
print(f" 📊 Curva Tipos media:  {final_df['curva_tipos'].mean():.2f}
pts")
print("-" * 55)

dist = final_df['target'].value_counts(normalize=True).sort_index()
labels = {0: "VENTA (Bajista) ", 1: "NEUTRAL (Estable)", 2: "COMPRA
(Alcista) "}

for clase, pct in dist.items():
    print(f" 📊 Clase {clase} [{labels[clase]}]: {pct*100:6.2f}%")

print("="*55)
print(" ✅ Proceso finalizado. El dataset está listo para entrenar.")
print("="*55 + "\n")

return final_df
# Ejecutar
df_ready = procesar_dataset_maestro()

```

Figura 33. Feature Engineering.

Entrenamiento y Evaluación del Modelo Predictivo (XGBoost)

En esta fase se implementa el algoritmo de Gradient Boosting mediante la librería XGBoost. Se ha optado por un enfoque de Validación Temporal mediante Split Cronológico (**Out-of-Sample**), entrenando el modelo con el bloque de datos históricos hasta 2022 y evaluando su capacidad predictiva de forma estricta en el periodo posterior 2023-2025. Este método garantiza que el modelo no tenga "sesgo de mirada al futuro" (look-ahead bias), simulando un entorno operativo real. Además, se utiliza la métrica XGBoost y Gain Score para cuantificar la importancia de cada variable en la toma de decisiones del algoritmo.

```
#
=====
# 4. ENTRENAMIENTO Y EVALUACIÓN DEL MODELO XGBOOST
#
=====

import pandas as pd
import numpy as np
import xgboost as xgb
from sklearn.metrics import classification_report, confusion_matrix,
accuracy_score
import matplotlib.pyplot as plt
import seaborn as sns
import warnings

warnings.filterwarnings('ignore')

# 1. CARGA Y CONTROL DE CALIDAD
df = pd.read_csv('tabla_maestra_tfm.csv')
df['Date'] = pd.to_datetime(df['Date'])
df = df.sort_values(['Date', 'ticker'])

# 2. OPTIMIZACIÓN PREDICTIVA (Shift temporal del target)
# Alineamos las variables de hoy para predecir el comportamiento del mes
siguiente
df['target_predictivo'] = df.groupby('ticker')['target'].shift(-1)
df_modelo = df.dropna(subset=['target_predictivo']).copy()

features = ['rsi', 'macd_hist', 'ret_1m', 'dist_sma_200', 'vix',
            'inflacion_anual', 'curva_tipos', 'bono_10y']
X = df_modelo[features]
y = df_modelo['target_predictivo']

# 3. DIVISIÓN TEMPORAL (Hold-out Method Cronológico)
# Se evita el uso de Shuffle para respetar la naturaleza de las series
temporales
train_mask = df_modelo['Date'] < '2023-01-01'
X_train, X_test = X[train_mask], X[~train_mask]
y_train, y_test = y[train_mask], y[~train_mask]

# 4. CONFIGURACIÓN DEL MODELO XGBOOST
# Parametrización para evitar el sobreajuste (max_depth bajo y
learning_rate controlado)
model = xgb.XGBClassifier(
    n_estimators=300,
```

```

        max_depth=3,
        learning_rate=0.01,
        gamma=1,
        subsample=0.8,
        colsample_bytree=0.8,
        objective='multi:softprob',
        random_state=42
    )

    model.fit(X_train, y_train)

    # 5. EVALUACIÓN Y MÉTRICAS DE CLASIFICACIÓN
    y_pred = model.predict(X_test)
    y_probs = model.predict_proba(X_test)

    print(f"Accuracy en Test: {accuracy_score(y_test, y_pred):.2%}")
    print(classification_report(y_test, y_pred, zero_division=0))

    # 6. VISUALIZACIÓN: MATRIZ DE CONFUSIÓN
    plt.figure(figsize=(8, 6))
    cm = confusion_matrix(y_test, y_pred)
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
                xticklabels=['Venta (0)', 'Neutral (1)', 'Compra (2)'],
                yticklabels=['Venta (0)', 'Neutral (1)', 'Compra (2)'])
    plt.title('Matriz de Confusión: Evaluación del Poder Predictivo')
    plt.show()

    # 7. ANÁLISIS DE IMPORTANCIA DE VARIABLES (Interpretación del Modelo)
    importancias = model.get_booster().get_score(importance_type='gain')
    df_imp = pd.DataFrame({
        'Feature': list(importancias.keys()),
        'Gain': list(importancias.values())
    }).sort_values(by='Gain', ascending=True)

    plt.figure(figsize=(10, 6))
    bars = plt.barh(df_imp['Feature'], df_imp['Gain'], color='tab:blue')

    # Inserción de etiquetas de valor para facilitar la lectura del gráfico
    for bar in bars:
        width = bar.get_width()
        plt.text(width + (width * 0.01), bar.get_y() + bar.get_height()/2,
                 f'{width:.2f}', va='center', fontsize=10, fontweight='bold')

    plt.title('Importancia de las Variables (Gain Score)')
    plt.grid(axis='x', linestyle='--', alpha=0.7)
    plt.tight_layout()
    plt.show()

    # 8. EXPORTACIÓN DE RESULTADOS PARA BACKTESTING
    df_test = df_modelo[~train_mask].copy()
    df_test['prediccion'] = y_pred
    df_test['prob_compra'] = y_probs[:, 2]

    df_predicciones = df_test[['Date', 'ticker', 'target', 'prediccion',
                              'prob_compra']]
    df_predicciones.to_csv('predicciones_modelo.csv', index=False)

```

Figura 34. Entrenamiento y Evaluación del Modelo Predictivo (XGBoost).

Simulador de Carteras y Backtesting Dinámico

Este módulo transforma las predicciones probabilísticas del modelo XGBoost en una estrategia de inversión ejecutable. A diferencia de un *backtest* simple, este simulador incorpora **fricciones de mercado** (comisiones) y permite comparar el rendimiento de la IA contra tres pilares económicos: el mercado variable (**S&P 500**), la renta fija (**Bono 10Y**) y la pérdida de poder adquisitivo (**Inflación**).

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings

# =====
# 5. Simulador de carteras
# =====

# Desactivar avisos innecesarios de librerías
warnings.filterwarnings('ignore')
# =====
# 1. PREPARACIÓN DE DATOS (UNIÓN DE PREDICCIONES + TABLA MAESTRA)
# =====
# Cargamos predicciones del XGBoost y la tabla maestra para recuperar datos macro
df_preds = pd.read_csv('predicciones_modelo.csv')
df_maestra = pd.read_csv('tabla_maestra_tfm.csv')

df_preds['Date'] = pd.to_datetime(df_preds['Date'])
df_maestra['Date'] = pd.to_datetime(df_maestra['Date'])

# Unimos para tener en un solo dataframe: prob_compra, vix, ret_1m, bono_10y,
# inflacion_anual
df_backtest = pd.merge(df_preds,
                        df_maestra[['Date', 'ticker', 'vix', 'ret_1m', 'bono_10y',
                                     'inflacion_anual']],
                        on=['Date', 'ticker'], how='left')

# =====
# 2. CÁLCULO DE BENCHMARKS (S&P 500, BONOS, INFLACIÓN)
# =====
# S&P 500: Media de todos los retornos en el dataset
sp500_ret = df_backtest.groupby('Date')['ret_1m'].mean()
cum_sp500 = (1 + sp500_ret).cumprod()
# Añadimos el punto inicial 1.0 para el gráfico
cum_sp500 = pd.concat([pd.Series([1.0], index=[cum_sp500.index[0] -
pd.DateOffset(months=1)]), cum_sp500])

# Umbrales Macro (Inflación y Bonos) basados en promedios del dataset
avg_inf = df_backtest['inflacion_anual'].mean() / 100
avg_bono = df_backtest['bono_10y'].mean() / 100
cum_inflacion = pd.Series([(1 + avg_inf/12)**i for i in range(len(cum_sp500))],
index=cum_sp500.index)
cum_bono = pd.Series([(1 + avg_bono/12)**i for i in range(len(cum_sp500))],
index=cum_sp500.index)

# =====
# 3. SIMULADOR MONETARIO DETALLADO
# =====
```

```
def simulate_monetary(top_n, capital_inicial):
    capital_acumulado = [capital_inicial]
    portfolio_logs = []
    comision_operacion = 0.005 # 0.5% de fricción mensual
    dates = sorted(df_backtest['Date'].unique())
    capital_actual = capital_inicial

    for i in range(len(dates) - 1):
        fecha_actual = dates[i]
        fecha_ejecucion = dates[i+1]

        current_preds = df_backtest[df_backtest['Date'] == fecha_actual]
        # Selección basada en la probabilidad de la clase "Compra" (2) del XGBoost
        top_picks = current_preds[current_preds['prob_compra'] > 0.45].nlargest(top_n,
'prob_compra')

        if len(top_picks) > 0:
            tickers_elegidos = top_picks['ticker'].tolist()
            datos_futuros = df_backtest[(df_backtest['Date'] == fecha_ejecucion) &
(df_backtest['ticker'].isin(tickers_elegidos))]
            avg_return = datos_futuros['ret_1m'].mean() - comision_operacion
        else:
            tickers_elegidos = ["CASH"]
            avg_return = 0.0

        capital_actual = capital_actual * (1 + avg_return)
        capital_acumulado.append(capital_actual)

        portfolio_logs.append({
            'Fecha': fecha_ejecucion,
            'Tickers': ", ".join(tickers_elegidos),
            'Rentabilidad_Mes': f"{avg_return:.2%}",
            'Valor_Cartera_USD': round(capital_actual, 2),
            'vix_nivel': current_preds['vix'].mean()
        })

    return pd.Series(capital_acumulado, index=dates), portfolio_logs

# EJECUCIÓN DE SIMULACIONES
cap_final_5, logs_5 = simulate_monetary(5, 5000)
cap_final_10, logs_10 = simulate_monetary(10, 10000)

# =====
# 4. REPORTE DE ACCIONES ELEGIDAS (ÚLTIMO SEMESTRE)
# =====
print("\n" + "="*70)
print("ACCIONES ELEGIDAS POR LA IA (ÚLTIMO SEMESTRE)")
print("="*70)

for i in range(-6, 0):
    try:
        fecha_display = logs_5[i]['Fecha'].strftime('%Y-%m')
        print(f"MES: {fecha_display}")
        print(f"> TOP 5 ($5k): {logs_5[i]['Tickers']}")
        print(f"> TOP 10 ($10k): {logs_10[i]['Tickers']}")
        print("-" * 40)
    except IndexError:
        continue

# =====
# 5. GRÁFICO 1: RENTABILIDAD ACUMULADA + VIX
```

```
# =====
plt.figure(figsize=(14, 8))
ax1 = plt.gca()

ax1.plot(cap_final_5.index, cap_final_5 / 5000, label=f'IA Top 5 ({((cap_final_5.iloc[-1]/5000)-1):.1%})', color='darkgreen', linewidth=2.5, zorder=5)
ax1.plot(cap_final_10.index, cap_final_10 / 10000, label=f'IA Top 10 ({((cap_final_10.iloc[-1]/10000)-1):.1%})', color='royalblue', linewidth=2, zorder=4)
ax1.plot(cum_sp500.index, cum_sp500, label=f'S&P 500 ({cum_sp500.iloc[-1]-1:.1%})', color='red', linestyle='--', alpha=0.7, zorder=3)
ax1.plot(cum_bono.index, cum_bono, label='Bono 10Y', color='purple', linestyle=':', linewidth=1.2)
ax1.plot(cum_inflacion.index, cum_inflacion, label='Inflación', color='orange', linestyle='-.', linewidth=1.2)

# Eje secundario para el VIX (Sombreado Plata Oscuro)
ax2 = ax1.twinx()
vix_mensual = df_backtest.groupby('Date')['vix'].mean().reindex(cap_final_5.index)
ax2.fill_between(vix_mensual.index, 0, vix_mensual, color='silver', alpha=0.4, label='VIX (Miedo)', zorder=1)

ax2.set_ylim(0, 50)
ax2.set_ylabel('Nivel del VIX', color='gray')

ax1.axhline(1, color='black', lw=1, alpha=0.5)
ax1.set_title('Rentabilidad Acumulada vs Escenario Macro y Volatilidad', fontsize=14, fontweight='bold')
ax1.set_ylabel('Crecimiento de la Inversión (Base 1.0)')
ax1.grid(True, alpha=0.2)

# Unir leyendas de ambos ejes
lines, labels = ax1.get_legend_handles_labels()
lines2, labels2 = ax2.get_legend_handles_labels()
ax1.legend(lines + lines2, labels + labels2, loc='upper left', bbox_to_anchor=(1.05, 1))

plt.tight_layout()
plt.show()

# =====
# 6. INFORME ECONÓMICO FINAL (ROI Y ALPHA)
# =====
beneficio_5 = cap_final_5.iloc[-1] - 5000
beneficio_10 = cap_final_10.iloc[-1] - 10000
rendimiento_sp500_decimal = cum_sp500.iloc[-1] - 1
valor_final_sp500_5k = 5000 * (1 + rendimiento_sp500_decimal)
valor_final_sp500_10k = 10000 * (1 + rendimiento_sp500_decimal)

print("\n" + "="*95)
print("INFORME DE RENDIMIENTO ECONÓMICO FINAL: IA VS ESTRATEGIA PASIVA (2023-2025)")
print("="*95)
print(f"{'MÉTRICA':<22} | {'IA TOP 5':<15} | {'S&P 500 ($5k)':<15} || {'IA TOP 10':<15} | {'S&P 500 ($10k)':<15}")
print("-" * 95)
print(f"{'Inversión Inicial':<22} | {'$5,000.00':<15} | {'$5,000.00':<15} || {'$10,000.00':<15} | {'$10,000.00':<15}")
print(f"{'Valor Final':<22} | ${cap_final_5.iloc[-1]:<14,.2f} | ${valor_final_sp500_5k:<14,.2f} || ${cap_final_10.iloc[-1]:<14,.2f} | ${valor_final_sp500_10k:<14,.2f}")
print(f"{'BENEFICIO NETO':<22} | ${beneficio_5:<14,.2f} | ${valor_final_sp500_5k-5000:<14,.2f} || ${beneficio_10:<14,.2f} | ${valor_final_sp500_10k-10000:<14,.2f}")
```

```
print(f"{'ROI Total (%)':<22} | {beneficio_5/5000*100:<14.2f}% |
{rendimiento_sp500_decimal*100:<14.2f}% || {beneficio_10/10000*100:<14.2f}% |
{rendimiento_sp500_decimal*100:<14.2f}%")
print("-" * 95)
print(f"{'ALPHA (Extra IA)':<22} | ${beneficio_5 - (valor_final_sp500_5k-5000):<14,.2f}
| {'-':<15} || ${beneficio_10 - (valor_final_sp500_10k-10000):<14,.2f} | {'-':<15}")
print("="*95)

# =====
# 7. GRÁFICO 2: EVOLUCIÓN DEL CAPITAL EN DÓLARES
# =====
plt.figure(figsize=(14, 7))
plt.plot(cap_final_5, label=f'Cartera IA Top 5 (Final: ${cap_final_5.iloc[-1]:,.0f})',
color='darkgreen', linewidth=3)
plt.plot(cap_final_10, label=f'Cartera IA Top 10 (Final: ${cap_final_10.iloc[-1]:,.0f})', color='royalblue', linewidth=3)
plt.plot(5000 * cum_sp500, label='S&P 500 (Ref. Inversión $5,000)', color='darkred',
linestyle='--', alpha=0.5)
plt.plot(10000 * cum_sp500, label='S&P 500 (Ref. Inversión $10,000)', color='red',
linestyle='--', alpha=0.5)

plt.title('Evolución del Valor de la Cartera en Dólares (USD)', fontsize=14)
plt.ylabel('Valor de la Inversión (USD)')
plt.legend(loc='upper left', bbox_to_anchor=(1, 1))
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

# =====
# 8. EXPORTACIÓN PARA DASHBOARD
# =====

# 1. Alineamos todas las series a un mismo índice (el de la cartera Top 5)
# Esto recorta o rellena lo que falte para que todos midan lo mismo
df_dashboard = pd.DataFrame(index=cap_final_5.index)

df_dashboard['IA_Top5'] = (cap_final_5 / 5000).values
df_dashboard['IA_Top10'] = (cap_final_10 / 10000).values

# El S&P 500 a veces tiene un elemento más, lo reindexamos para que coincida
df_dashboard['SP500'] = cum_sp500.reindex(cap_final_5.index).values

# 2. Recuperamos los datos macro
macro_mensual = df_backtest.groupby('Date').agg({
    'vix': 'mean',
    'bono_10y': 'mean'
}).reindex(cap_final_5.index).fillna(method='ffill')

df_dashboard['VIX'] = macro_mensual['vix'].values
df_dashboard['GS10'] = macro_mensual['bono_10y'].values

# 3. Reseteamos el índice para que la Fecha sea una columna
df_dashboard = df_dashboard.reset_index()
df_dashboard.columns = ['Fecha', 'IA_Top5', 'IA_Top10', 'SP500', 'VIX', 'GS10']

# 4. Añadimos columnas para la tabla del dashboard (última selección)
# Cogemos los tickers del último log disponible
ultima_fecha = logs_5[-1]['Fecha']
ultimos_tickers = logs_10[-1]['Tickers'] # Usamos Top 10 para la tabla

df_dashboard['Ticker'] = ultimos_tickers
```

```
df_dashboard['Probabilidad'] = 0.85 # Valor representativo
df_dashboard['Sector'] = "Mix (Tecnología/Finanzas)"

# Guardar
df_dashboard.to_csv("dataset_tfm_dashboard.csv", index=False)
print("\n✅ Archivo 'dataset_tfm_dashboard.csv' generado correctamente")
```

Figura 35. Simulador de carteras.

Dashboard de Inteligencia de Mercado y Gestión de Carteras

Este último módulo integra todos los resultados del sistema en una interfaz visual unificada. El dashboard permite realizar un análisis comparativo de la eficiencia (Riesgo vs. Retorno) y monitorizar la composición de las carteras Top 5 y Top 10 en tiempo real. La visualización incluye indicadores macroeconómicos de contexto (VIX y Tipos de Interés) para facilitar la interpretación del rendimiento de la Inteligencia Artificial en diferentes ciclos económicos.

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np

# =====
# 6. Dashboard visual
# =====

# 1. Cargar datos
df = pd.read_csv("dataset_tfm_dashboard.csv")
df['Fecha'] = pd.to_datetime(df['Fecha'])

# 2. Cálculos de métricas
def get_metrics(col):
    retornos = df[col].pct_change().dropna()
    return retornos.mean() * 12, retornos.std() * np.sqrt(12)

ret_5, std_5 = get_metrics('IA_Top5')
ret_10, std_10 = get_metrics('IA_Top10')
ret_sp, std_sp = get_metrics('SP500')

# 3. Configurar el Dashboard Total (5 niveles para que quepa TODO)
fig = plt.figure(figsize=(20, 22))
gs = fig.add_gridspec(5, 2, height_ratios=[1.5, 1, 1, 1, 0.4], hspace=0.4)

# --- PANEL 1: Curva de Equidad (Arriba, ocupa todo el ancho) ---
ax1 = fig.add_subplot(gs[0, :])
ax1.plot(df['Fecha'], df['IA_Top5'], color='#1B5E20', lw=4, label='Estrategia IA Top 5 (Máxima Convicción)')
ax1.plot(df['Fecha'], df['IA_Top10'], color='#0D47A1', lw=2.5, label='Estrategia IA Top 10 (Diversificada)')
ax1.plot(df['Fecha'], df['SP500'], color='#B71C1C', ls='--', alpha=0.5, label='S&P 500 (Mercado)')
ax1.fill_between(df['Fecha'], df['IA_Top5'], df['SP500'], where=(df['IA_Top5'] >= df['SP500']), color='green', alpha=0.1, label='Alpha Generado')
ax1.set_title('COMPARATIVA HISTÓRICA: VALOR DE LA INVERSIÓN', fontsize=18, fontweight='bold')
ax1.legend(loc='upper left', fontsize=12)
ax1.grid(True, alpha=0.2)
```



```
# --- PANEL 2: Riesgo vs Retorno (Scatter Plot) ---
ax2 = fig.add_subplot(gs[1, 0])
ax2.scatter(std_sp, ret_sp, color='red', s=150, label='S&P 500')
ax2.scatter(std_10, ret_10, color='blue', s=150, label='IA Top 10')
ax2.scatter(std_5, ret_5, color='green', s=250, marker='*', label='IA Top 5 (Óptimo)')
ax2.set_title('EFICIENCIA: RIESGO VS RETORNO', fontsize=14, fontweight='bold')
ax2.set_xlabel('Volatilidad Anualizada')
ax2.set_ylabel('Retorno Anualizado')
ax2.legend()
ax2.grid(True, alpha=0.3)

# --- PANEL 3: Volatilidad (VIX) ---
ax3 = fig.add_subplot(gs[1, 1])
ax3.fill_between(df['Fecha'], df['VIX'], color='gray', alpha=0.15)
ax3.plot(df['Fecha'], df['VIX'], color='#37474F', lw=1.5)
ax3.set_title('VOLATILIDAD (VIX)', fontsize=13, fontweight='bold')

# --- PANEL 4: Tipos de Interés (Bono 10Y) ---
ax4 = fig.add_subplot(gs[2, 0])
ax4.plot(df['Fecha'], df['GS10'], color='#6A1B9A', lw=2)
ax4.set_title('TIPOS DE INTERÉS (BONO 10Y)', fontsize=13, fontweight='bold')
ax4.grid(True, alpha=0.2)

# --- PANEL 5: Ponderación Top 5 (Donut 1) ---
ax5 = fig.add_subplot(gs[2, 1])
tickers_5 = df.iloc[-1]['Ticker'].split(', ')[0:5]
ax5.pie([20]*5, labels=tickers_5, autopct='%1.0f%%',
        colors=plt.cm.Greens(np.linspace(0.4, 0.8, 5)), startangle=90)
ax5.add_artist(plt.Circle((0,0), 0.70, fc='white'))
ax5.set_title("PESOS CARTERA TOP 5", fontsize=12, fontweight='bold')

# --- PANEL 6: Ponderación Top 10 (Donut 2) ---
ax6 = fig.add_subplot(gs[3, 0])
tickers_10 = df.iloc[-1]['Ticker'].split(', ')
ax6.pie([10]*10, labels=tickers_10, colors=plt.cm.Blues(np.linspace(0.3, 0.7, 10)),
        startangle=90)
ax6.add_artist(plt.Circle((0,0), 0.70, fc='white'))
ax6.set_title("PESOS CARTERA TOP 10", fontsize=12, fontweight='bold')

# --- PANEL 7: Título inferior y Fecha ---
ax_info = fig.add_subplot(gs[4, :])
ax_info.axis('off')
info = f"Fecha de Análisis: {df.iloc[-1]['Fecha'].strftime('%d/%m/%Y')} | Modelo:
XGBoost Classifier | Optimización: Máxima Convicción"
ax_info.text(0.5, 0.5, info, ha='center', va='center', fontsize=15, fontweight='bold',
            bbox=dict(facecolor='#F5F5F5', edgecolor='black', boxstyle='round,pad=1'))

plt.tight_layout()
plt.savefig("DASHBOARD_COMPLETO_FINAL.png", dpi=300)
plt.show()
```

Figura 36. Dashboard visual.

7.3. Protocolo de Replicabilidad (Pipeline de Ejecución)

Para garantizar la integridad de los resultados, el proyecto implementa un enfoque de **"Zero-Configuration Reproducibility"** basado en fuentes de datos abiertas (Yahoo Finance) y un sistema de **Checkpointing** que permite la ejecución independiente de cada bloque.

Requisitos y Configuración Inicial

1. **Entorno:** Se recomienda **Google Colab** para evitar conflictos de versiones locales.
2. **Paso Crítico de Instalación:** Ejecutar el **Bloque 0** para instalar las dependencias.
 - *Nota:* Tras la instalación, es **imprescindible reiniciar la sesión** (Entorno de ejecución > Reiniciar sesión) antes de continuar para cargar las nuevas versiones de Pandas y Numpy en la RAM

Secuencia del Pipeline Modular

Para replicar el experimento, el evaluador debe seguir el orden de las celdas, las cuales generan archivos .csv intermedios para validar cada etapa:

- **Bloque 1 (Extracción):** Realiza el *scraping* de Wikipedia y descarga datos de 50 activos estratificados, generando el fichero **"universo_tfm.csv"**.
- **Bloque 2 (EDA):** Genera el análisis descriptivo por sectores GICS genera un gráfico de número de acciones por sector.
- **Bloque 3 (Feature Engineering):** Sincroniza indicadores técnicos y la matriz macroeconómica (^VIX, ^TNX, ^IRX) generando es fichero **"tabla_maestra_tfm.csv"**.
- **Bloque 4 (ML):** Entrena el modelo XGBoost y exporta las señales en el fichero **"predicciones_modelo.csv"**.
- **Bloque 5 y 6 (Resultados):** Ejecuta el backtesting y genera el **Dashboard de Resultados Consolidado "dataset_tfm_dashboard.csv"**, donde se visualiza el Alpha generado frente al S&P 500.

Verificación de Integridad

La replicación se considera exitosa si el sistema genera automáticamente el informe comparativo de rentabilidad (Top 5 vs S&P 500), validando la capacidad de la IA para preservar el valor de la inversión en el entorno 2015-2025.

7.4. Repositorio Digital y Entregables (GitHub)

Como elemento fundamental para la contextualización y valoración del proyecto, se ha habilitado un repositorio oficial donde reside el ecosistema digital completo:

- **Enlace al Repositorio:** [Accede al repositorio de GitHub](#)
- **Contenido del Repositorio:**
 - **Notebook Maestro (.ipynb):** Contiene el código fuente completo, desde la fase de *web scraping* y *feature engineering* hasta el entrenamiento del modelo XGBoost y el simulador de carteras. Incluye celdas pre-renderizadas para una inspección inmediata de los resultados sin necesidad de ejecución.
 - **Documentación Técnica (README):** Documento detallado en formato Markdown que describe la arquitectura del proyecto, las fuentes de datos utilizadas y las instrucciones paso a paso para la replicación del experimento.
 - **Gestión de Dependencias (requirements.txt):** Archivo que lista las librerías y versiones específicas necesarias (XGBoost, Pandas_TA,, etc.) para asegurar la estabilidad del entorno de ejecución.
 - **Memoria definitiva TFM:** Versión final del trabajo en formato PDF para asegurar la coherencia entre el código y la documentación teórica.